Identificación y Control Adaptativo
Modelos y Predictores

Pablo Gonzalez

FIUBA

2026

1. Planteo del problema
2. Resolución numérica
3. Algoritmos de Estimación
   - Aproximación heurística
   - Algoritmo de proyección
   - Aproximación estocástica
   - Método del gradiente
   - Variables Instrumentales
4. Modelos y Predictores
   - Modelo ARMAX
   - Modelo Box-Jenkin (BJ)
   - Modelo OE
   - Resumen

Según el criterio de estimación (qué magnitud se busca minimizar) se distinguen:

- **Mínimos cuadrados (LS)**: minimiza la suma del error cuadrático (visto como error de ajuste)
- **Predicción de error (PEM)**: minimiza el error de predicción; es el criterio más general en identificación de sistemas. Volvemos sobre este criterio al final de la presentación.
- **Máxima verosimilitud (ML)**: maximiza la probabilidad de observar los datos dados los parámetros; en ruido gaussiano se reduce a LS.

LS: minimizamos $\sum (y - y_k \cdot \theta)^2$

PEM: minimizamos $\sum (y_k - \hat{y}_k)^2$ no necesariamente lineal

- Se busca elegir los parámetros θ que hacen más probable la observación de los datos $L(\theta) = p(Y|\theta)$

$$\hat{\theta}_{ML} = \arg\max_{\theta} \log L(\theta)$$

- Equivalencia con LS: si los residuos son independientes, gaussianos, de media nula y varianza constante σ^2:

$$e_k = y_k - \hat{y}_k(\theta) \sim \mathcal{N}(0, \sigma^2)$$

Por independencia, la verosimilitud de los datos es:

$$L(\theta) = \prod_{k=1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{e_k^2}{2\sigma^2}\right]$$

Máxima verosimilitud y mínimos cuadrados dan el mismo resultado SI ASUMIMOS QUE LOS RESIDUOS SON GAUSSIANOS.

Maximizar la verosimilitud equivale a maximizar su logaritmo:

$$\hat{\theta}_{ML} = \arg\max_{\theta} \log L(\theta) = \arg\min_{\theta} \sum_{k=1}^{N} e_k^2 \quad \Longrightarrow \quad \hat{\theta}_{ML} = \hat{\theta}_{LS}$$

- Bajo otras hipótesis probabilísticas, ML puede conducir a criterios de estimación diferentes de LS.

1. Planteo del problema
2. Resolución numérica
3. Algoritmos de Estimación
   - Aproximación heurística
   - Algoritmo de proyección
   - Aproximación estocástica
   - Método del gradiente
   - Variables Instrumentales
4. Modelos y Predictores
   - Modelo ARMAX
   - Modelo Box-Jenkin (BJ)
   - Modelo OE
   - Resumen

Métodos de optimización aplicables a los criterios vistos:

- **Gradiente descendente**: actualización iterativa según el gradiente del error.

$$\Delta\theta = -\mu \nabla_\theta J(\theta)$$

- **Método de Newton / Gauss-Newton**: usan derivadas segundas (o aproximadas) para acelerar convergencia.

$$\Delta\theta = (J_\theta^\top J_\theta)^{-1} J_\theta^\top e$$

  donde J_θ es el jacobiano de los errores

- **Levenberg–Marquardt**: mezcla entre gradiente y Gauss-Newton (usado en redes neuronales y PEM).

$$\Delta\theta = (J_\theta^\top J_\theta + \lambda \mathbb{I})^{-1} J_\theta^\top e$$

- **Método recursivo (RLS)**: versión en línea del LS, actualiza con cada nueva muestra.

↳ Este es el que vimos la clase pasada, el que se va actualizando a medida que llega información.

$$V = \frac{1}{2}\sum e_k^2 = \frac{1}{2}\sum (y_k - \hat{y}_k)^2 = \frac{1}{2}\|\varepsilon\|^2 \quad \text{donde} \quad \varepsilon = \begin{bmatrix} e_k \\ \vdots \\ e_1 \end{bmatrix} ; \ \varepsilon(\theta)$$

Buscamos: $\hat{\theta} = \arg\min_{\theta} V = \arg\min_{\theta} \frac{1}{2}\|\varepsilon(\theta)\|^2$

ε puede ser no lineal en los parámetros (si no, esto se reduce a LS)

$$\varepsilon^{(i+1)} = \varepsilon^{(i)} + J.\Delta\theta \Rightarrow V = \frac{1}{2}\|\varepsilon^{(i)} + J.\Delta\theta\|^2$$

↳ matriz jacobiana

$$J = \left[d\varepsilon / d\theta \right]$$

Entonces, queremos minimizar $V \cong \|\varepsilon + J.\Delta\theta\|^2$

Para esto es necesario que $\varepsilon + J.\Delta\theta = 0 \rightsquigarrow J^t.J.\Delta\theta = -J^t.\varepsilon$ (Cuadrados mínimos)

Esto se llama método de Gauss-Newton $\rightarrow \Delta\theta = -(J^t.J)^{-1}.J^t.\varepsilon$

$$\rightarrow \theta^{(i+1)} = \theta^{(i)} + \Delta\theta$$

Por cada iteración hallamos un delta theta por mínimos cuadrados

¿Qué pasa si $\nexists (J^t.J)^{-1}$? → Levenberg-Marquardt

Agrega un término más: $J^t.J + \lambda.I$ → fuerza a q' exista la inversa

1 PLANTEO DEL PROBLEMA

2 RESOLUCIÓN NUMÉRICA

3 ALGORITMOS DE ESTIMACIÓN
- Aproximación heurística
- Algoritmo de proyección
- Aproximación estocástica
- Método del gradiente
- Variables Instrumentales

4 MODELOS Y PREDICTORES
- Modelo ARMAX
- Modelo Box-Jenkin (BJ)
- Modelo OE
- Resumen

Dada una planta de primer orden, con el parámetro a conocido

$$
\begin{aligned}
y_{k+1} &= a\,y_k + b\,u_k \\
\hat{y}_{k+1} &= a\,y_k + \hat{b}\,u_k \\
e_{k+1} &= y_{k+1} - \hat{y}_{k+1} = (b - \hat{b})u_k
\end{aligned}
$$

Propongo u_k escalón

$$
\begin{aligned}
e_{k+1} &= b - \hat{b} \\
b &= \hat{b} + e_{k+1}
\end{aligned}
$$

Donde reinterpretamos esta ecuación en forma recursiva pensando que b es la estimación en $k+1$

$$\hat{b}_{k+1} = \hat{b} + \gamma\, e_{k+1}$$

Si el escalón es negativo, el algoritmo anterior no funciona. Se ajusta la ganancia con el signo de u_k

$$\hat{b}_{k+1} = \hat{b} + \gamma \frac{u_k}{|u_k|} e_{k+1} \quad .$$

A fin de vectorizar, una mejor versión es el algoritmo de *Kaczmarz* Cachafás

$$\hat{b}_{k+1} = \hat{b} + \gamma \frac{u_k}{u_k^2} e_{k+1}$$

Se puede regularizar para que el denominador no se anule

$$\hat{b}_{k+1} = \hat{b} + \gamma \frac{u_k}{1 + u_k^2} e_{k+1}$$

Definimos

- Error *a priori*: $e_{k+1} = y_{k+1} - \hat{y}_{k+1}$, donde $\hat{y}_{k+1} = \varphi_k^\top \theta_k$
- Error *a posteriori*: $\bar{e}_{k+1} = y_{k+1} - \bar{y}_{k+1}$, donde $\bar{y}_{k+1} = \varphi_k^\top \theta_{k+1}$

Entonces,

$$\hat{b}_{k+1} = \hat{b}_k + \gamma \cdot \frac{u_k}{1+u_k^2} e_{k+1}$$

$$\begin{aligned}\bar{y}_{k+1} &= a\, y_k + \hat{b}_{k+1} u_k \\ &= \left(a\, y_k + \hat{b}_k u_k\right) + \gamma \frac{u_k^2}{1+u_k^2} e_{k+1}\end{aligned}$$

$$\bar{y}_{k+1} = \hat{y}_{k+1} + \gamma \frac{u_k^2}{1+u_k^2} e_{k+1}$$

$$\bar{e}_{k+1} = y_{k+1} - \left(\hat{y}_{k+1} + \gamma \frac{u_k^2}{1+u_k^2} e_{k+1}\right)$$

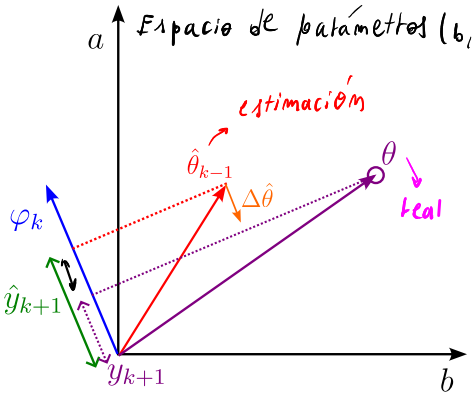
Finalmente, el error *a posteriori* es menor que el error *a priori*

Learning rate

$$\bar{e}_{k+1} = \left(1 - \gamma \frac{u_k^2}{1+u_k^2}\right) e_{k+1}$$

$\therefore \bar{e}_{k+1} < e_{k+1}$ El error a posteriori es menor q' el error a priori

- La predicción $\hat{y}_{k+1} = \varphi_k^\top \hat{\theta}_k$ expresa una proyección del vector de parámetros sobre las mediciones
- Se propone ajustar $\hat{\theta}$ según la dirección de φ_k y el error de proyección



Del planteo geométrico surge,

$$\hat{\theta}_k = \hat{\theta}_{k-1} + \lambda\, \varphi_k$$
$$\lambda = \frac{\gamma}{\|\varphi_k\|^2}\left(y_k - \varphi_k^\top \hat{\theta}_{k-1}\right)$$

Regularizando para $\alpha > 0$,

$$\hat{\theta}_k = \hat{\theta}_{k-1} + \frac{\gamma\, \varphi_k}{\alpha + \varphi_k^\top \varphi_k}\left(y_k - \varphi_k^\top \hat{\theta}_{k-1}\right)$$

Comparar con RLS

Supongamos que θ_0 es el valor verdadero convencional de los parámetros. Definimos el incremento:

$$\tilde{\theta} = \hat{\theta} - \theta_0$$

Reemplazando en la ec. de actualización de los parámetros,

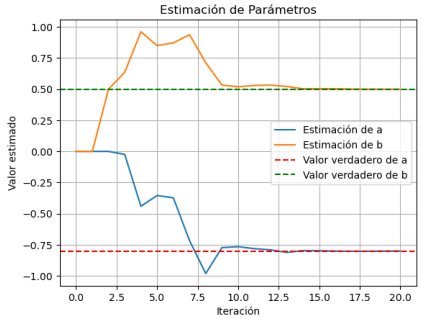
$$\tilde{\theta}_k = \tilde{\theta}_{k-1} + \frac{\gamma\,\varphi_k}{\alpha + \varphi_k^\top \varphi_k}\left(\varphi_k^\top \theta_0 - \varphi_k^\top \hat{\theta}_{k-1}\right) = \tilde{\theta}_{k-1} - \frac{\gamma\,\varphi_k \varphi_k^\top}{\alpha + \varphi_k^\top \varphi_k}\tilde{\theta}_{k-1}$$

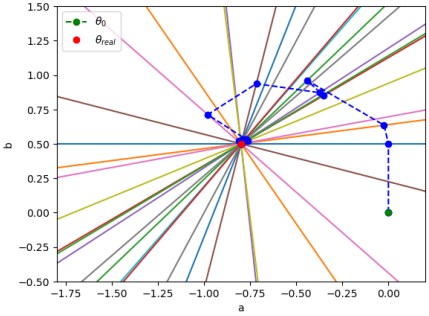
que describe la ecuación de actualización del estado con la matriz de transición

$$\Phi = \mathbb{I} - \frac{\gamma\,\varphi_k \varphi_k^\top}{\alpha + \varphi_k^\top \varphi_k} \qquad \text{con} \quad \lambda = \frac{\alpha + (1-\gamma)\,\varphi_k \varphi_k^\top}{\alpha + \varphi_k^\top \varphi_k}$$

Para convergencia se pide $|\lambda| < 1$, y por lo tanto $0 < \gamma < 2$

$$y_k = a\,y_{k-1} + b\,u_{k-1}$$ Ah hell mah





Ver notebook con el ejemplo

Comparando los algortimos vistos hasta aquí, se observa la misma forma en todos ellos:

- Mínimos cuadrados

$$\hat{\theta}_k = \hat{\theta}_{k-1} + P_k \varphi_k \left(y_k - \varphi_k^\top \hat{\theta}_{k-1} \right)$$

- Heurístico

$$\hat{\theta}_k = \hat{\theta}_{k-1} + \frac{\gamma}{1 + \varphi^\top \varphi} \varphi_k \left(y_k - \varphi_k^\top \hat{\theta}_{k-1} \right)$$

- Proyección

$$\hat{\theta}_k = \hat{\theta}_{k-1} + \frac{\gamma}{\alpha + \varphi^\top \varphi} \varphi_k \left(y_k - \varphi_k^\top \hat{\theta}_{k-1} \right)$$

Se propone la aproximación estocástica con la misma estructura

$$\hat{\theta}_k = \hat{\theta}_{k-1} + p_k \varphi_k \left(y_k - \varphi_k^\top \hat{\theta}_{k-1} \right)$$

donde p_k es una función decreciente en k

En los métodos anteriores se observa:

- LS minimiza $J_k = E_k^t E_k$ con la *pseudoinversa* de la matriz de observación
- RLS aplica pequeñas correcciones en cada iteración, pero siempre resolviendo linealmente

Tomando estas ideas se puede hacer un planteo más general sobre la actualización de la estimación

$$\hat{\theta}_{k+1} = \hat{\theta}_k - F \frac{\partial J_{k+1}}{\partial \hat{\theta}_k}$$

El gradiente se obtiene derivando (numéricamente) el funcional

$$\frac{\partial J_{k+1}}{\partial \hat{\theta}_k} = \frac{\partial e_{k+1}}{\partial \hat{\theta}_k} e_{k+1}$$

Para el caso lineal se reduce a los métodos vistos pues,

$$\frac{\partial J_{k+1}}{\partial \hat{\theta}_k} = -\varphi_k \, e_{k+1}$$

- Mínimos cuadrados puede producir estimaciones sesgadas cuando el regresor está correlacionado con la perturbación. (cuando se cierra el lazo, x' ej.)
- Reemplazar el regresor en las ecuaciones de estimación por una señal instrumental z que esté correlacionada con φ, pero no con la perturbación.

$$y_k = \varphi_k^\top \theta + e_k$$
$$\mathbb{E}[z_k\, y_k] = \mathbb{E}[z_k \varphi_k^\top]\theta + \mathbb{E}[z_k e_k]$$

Reemplazando la esperanza por promedios muestrales se tiene

$$\hat{\theta}_{\text{IV}} = \left(\sum z_k \varphi_k^\top\right)^{-1} \sum z_k y_k$$

¿Y qué z_k ponemos? ¿De dónde lo sacamos? La similitud es perturbadota...

En forma matricial resulta

$$\hat{\theta}_{IV} = (Z^\top \Phi)^{-1} Z^\top Y$$

$$\hat{\theta}_{LS} = (\Phi^t \cdot \Phi)^{-1} \Phi^t \cdot Y$$

Un instrumento válido debe satisfacer:

$$\underbrace{\mathbb{E}[z_k e_k] = 0}_{\text{Exogeneidad}}, \qquad \underbrace{\operatorname{rango} \mathbb{E}[z_k \varphi_k^\top] = n_\theta}_{\text{Relevancia}}$$

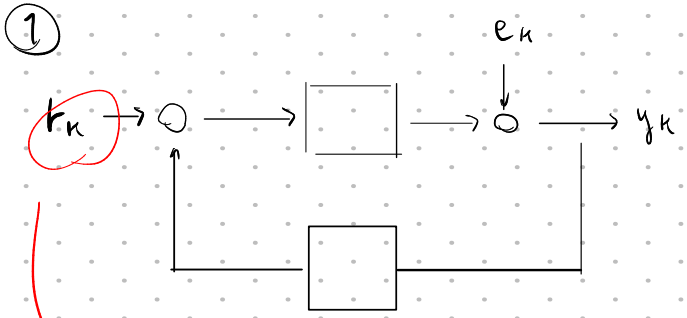
¿Cómo construir instrumentos adecuados? Consideremos un sistema representado por un modelo ARX e identificado en lazo cerrado. Debido a la realimentación, los regresores pueden estar correlacionados con el error de predicción.

1. **A partir de la referencia:** utilizar muestras pasadas de $r(t)$ como instrumentos. Si la referencia es independiente de las perturbaciones, resulta ortogonal al error; su relevancia depende de la excitación y de la dinámica del lazo.
2. **A partir de un modelo auxiliar:** estimar previamente un modelo por LS y simular su respuesta ante la referencia. Construir los instrumentos con las señales simuladas y_{sim} y u_{sim}, que dependen de la referencia y no de las perturbaciones de la medición.

Ver script de matlab con el ejemplo

Se puso tara esta materia...

1



Sacamos los z_k de acá, son independientes de e_k

$r_k \rightarrow u_k \rightarrow y_k$

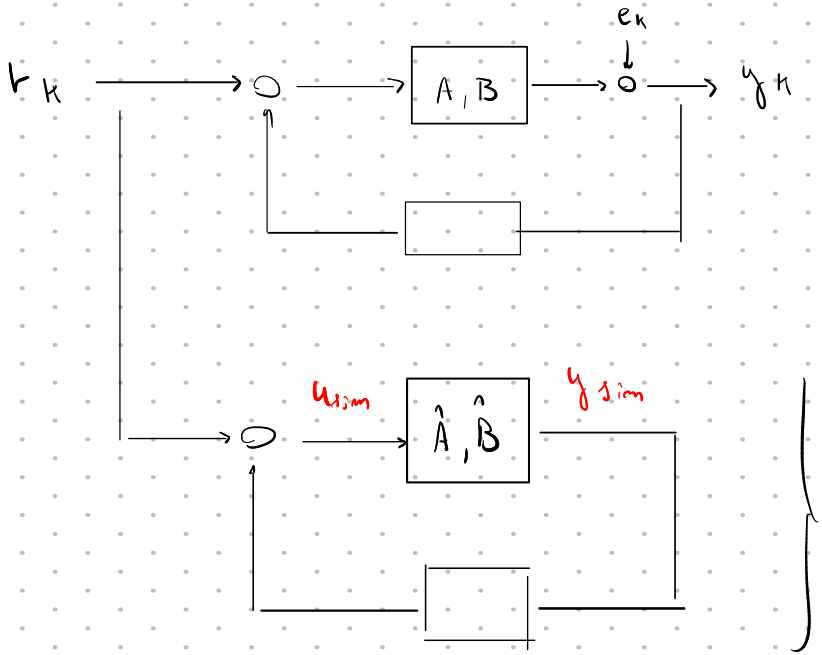
$$\hat{\theta} = (Z^t \cdot Z)^{-1} \cdot Z^t \cdot Y$$

$p \times N$; $N \times p$

$$\Rightarrow Z \in \mathbb{R}^{N \times p}$$

$$Z = \begin{bmatrix} r_k & r_{k-1} & r_{k-2} & \cdots & r_{k-p} \\ \cdot & & & & \\ \vdots & & & & \\ r_{k-N} & r_{k-N-1} & \cdots & & r_{k-N-p} \end{bmatrix}$$

2



- modelo estimado a partir de LS.
- Este modelo está sesgado
- Tomo como variables instrumentales a u_{sim} y a y_{sim}

ahora vimos 'identificacion_IV.m'

1. Planteo del problema
2. Resolución numérica
3. Algoritmos de Estimación
   - Aproximación heurística
   - Algoritmo de proyección
   - Aproximación estocástica
   - Método del gradiente
   - Variables Instrumentales
4. Modelos y Predictores
   - Modelo ARMAX
   - Modelo Box-Jenkin (BJ)
   - Modelo OE
   - Resumen

- **Objetivo**: Modelar la dinámica de la planta y construir predictores para estimar parámetros y/o residuos.
- **Flujo de trabajo**
  - Se parte de la planta
  - Se plantea un modelo (ARX, ARMAX, BJ, OE, etc.)
  - En función del modelo se define el predictor
  - Se plantea el estimador (RLS, RLSE, PEM, etc.)
  - Se obtiene el residuo

Modelo ARx: $Ay = Bu + e$ → ¿Dónde entra el ruido?

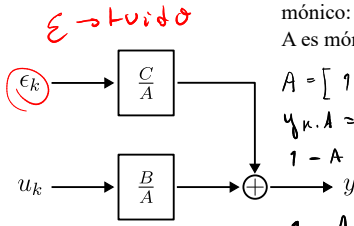
¿ $y = \frac{B}{A} \cdot u + e$?

- **Residuo**: es la diferencia entre lo que dice el modelo y lo que dice la planta

$$e_k = y_k - \hat{y}_k$$

Cada modelo tiene su forma de predictor

Es deseable que sea RB (ruido blanco); que no contenga información útil para la identificación. Se puede sofisticar el modelo para usar la información remanente.



$\epsilon \rightarrow$ ruido

mónico: polinomio cuyo primer coeficiente es 1

A es mónico

$A = [1\ a_1\ a_2 \ldots]$

$y_{k-1} = 1 \cdot y_k + a_1 y_{k-1} \ldots$

$1 - A = [-a_1\ -a_2 \ldots]$

$1 - A$ es otro polinomio, de grado $[\mathrm{Gr}(A) - 1]$

$$y_k = \frac{B}{A} u_k + \frac{C}{A} \epsilon_k$$

$$A\, y_k = B\, u_k + C\, \epsilon_k$$

- El polinomio A es *mónico*
- El polinomio C modela el ruido coloreado
- Notar la dependencia de y_k con valores anteriores de la perturbación ϵ_{k-1}, etc.
- Si se propone el predictor

$$\hat{y}_k = (1 - A) y_k + B u_k$$

el vector de parámetros obtenido por RLS resulta sesgado, ya que φ_k está correlacionado con ϵ_k

$A \cdot y = B \cdot u \rightarrow y_k + a_1 y_{k-1} \dots = b_1 \cdot u_{k-1} + b_2 u_{k-2} \dots$

y_k se convierte en el predictor $\hat{y}_k$

$\Rightarrow \hat{y}_k = -a_1 \cdot y_{k-1} - a_2 y_{k-2} \dots + b_1 u_{k-1} + b_2 u_{k-2} \dots$

$\Rightarrow \boxed{\hat{y}_k = (1 - A) \cdot y + B \cdot u}$

Ruido blanco

La ecuación de la planta perturbada con ϵ_k RB es:

Les cambié el signo xq' sí

Ser consistente, no como pablo...

$$y_k = a_1 y_{k-1} + \ldots + b_1 u_{k-1} + \ldots + \epsilon_k + c_1 \epsilon_{k-1} + \ldots$$

Una buena estimación es aquella cuyo residuo es RB. Se plantea el predictor:

¿De dónde las sacamos?

$$\hat{y}_k = \hat{a}_1 y_{k-1} + \ldots + \hat{b}_1 u_{k-1} + \ldots + \hat{c}_1 \epsilon_{k-1} + \ldots$$

que consigue descorrelacionar el regresor φ_k y la perturbación, recuperando las características deseadas en el residuo cuando se usa RLS

Residuo $= \varepsilon_k \triangleq y_k - \hat{y}_k \Rightarrow \hat{y}_k =$ Esto

$\hat{y}_k = \hat{a}_1 y_{k-1} \cdots + \hat{b}_1 u_{k-1} \cdots + \hat{c}\, \varepsilon_{k-1} = \varphi^T \cdot \theta$

Dado la ecuación del predictor

$$\hat{y}_k = \hat{a}_1\, y_{k-1} + \ldots + \hat{b}_1\, u_{k-1} + \ldots + \hat{c}_1\, \epsilon_{k-1} + \ldots$$

En el estimador por mínimos cuadrados se reinterpreta el vector regresor y el de parámetros

$$\varphi_k^\top = \begin{bmatrix} y_{k-1} & \ldots & u_{k-1} & \ldots & \epsilon_{k-1} & \ldots \end{bmatrix}$$
$$\theta_k^\top = \begin{bmatrix} \hat{a}_1 & \ldots & \hat{b}_1 & \ldots & \hat{c}_1 & \ldots \end{bmatrix}$$

FA - LO - PA

puede no converger, suele no converger.

Pero: ¿cómo se obtiene ϵ_k, si no se tiene acceso a esta señal?

Si bien la estimación de c es cualquier cosa, no nos importa xq no es parte de la planta.
Lo bueno de c es que se lleva la basura del ruido, dejando una estimación más limpia de a y de b

Para entender cómo realizar la estimación considerar:

- Convergencia: $e_k \to \epsilon_k$
- Bajo esta hipótesis, se estima ϵ_k con el error de predicción. La forma del predictor resulta:

$$\hat{y}_k = \hat{a}_1\, y_{k-1} + \ldots + \hat{b}_1\, u_{k-1} + \ldots + \hat{c}_1\, (y_{k-1} - \hat{y}_{k-1}) + \ldots$$

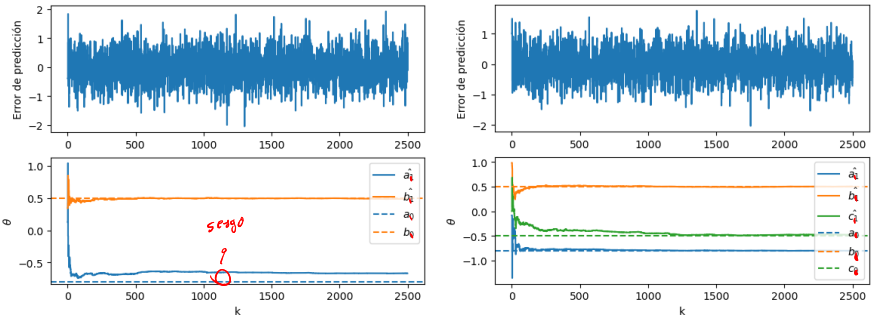
Para realizar la estimación, basta reinterpretar los vectores de RLS

$$\varphi_k^\top = \begin{bmatrix} y_{k-1} & \ldots & u_{k-1} & \ldots & (y_{k-1} - \hat{y}_{k-1}) & \ldots \end{bmatrix}$$
$$\theta_k^\top = \begin{bmatrix} \hat{a}_1 & \ldots & \hat{b}_1 & \ldots & \hat{c}_1 & \ldots \end{bmatrix}$$

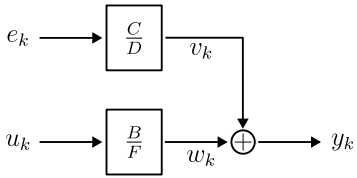
Particularidades:

- Los parámetros del ruido difícilmente convergen. Además no se usan en el control.
- Los parámetros de la planta convergen más lentamente que en modelos ARX

$$y_k = a\,y_{k-1} + b\,u_k + e_k + c\,e_{k-1}$$



Ver notebook con el ejemplo



$$y_k = \frac{B}{F}u_k + \frac{C}{D}e_k$$

- Los polinomios F, C y D son *mónicos*.
- Se puede llevar a la forma del predictor descorrelacionando primero e_k y luego expresando y_k en función de las muestras pasadas.

$$\frac{D}{C}y_k = \frac{D\,B}{C\,F}u_k + e_k$$
$$y_k = \left(1 - \frac{D}{C}\right)y_k + \frac{D\,B}{C\,F}u_k + e_k$$

Operando sobre la ecuación del modelo se llega al predictor:

$$y_k = \left(1 - \frac{D}{C}\right) y_k + \frac{D\,B}{C\,F} u_k + e_k$$

$$\hat{y}_k = \left(1 - \frac{D}{C}\right) y_k + \frac{D\,B}{C\,F} u_k$$

lo mismo, pero sin e_k

$$C\,F\,\hat{y}_k = (C\,F - D\,F)\,y_k + D\,B\,u_k$$

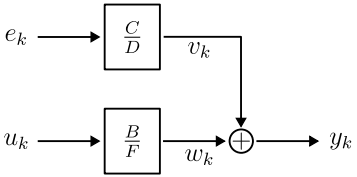
$$\hat{y}_k = (1 - C\,F)\,\hat{y}_k + (C\,F)\,y_k - (D\,F)\,y_k + D\,B\,u_k$$

Luego se reinterpreta el regresor para RLS según:

$$\varphi_k^\top = [\hat{y}_{k-1} \quad \dots \quad y_{k-1} \quad \dots \quad y_{k-1} \quad \dots \quad u_{k-1} \quad \dots]$$

Pero RLS dará los coeficientes de CD, DF y DB, que no sirven para el control.

⇒ No sirve así como está



El estimador se construye restando e_k

$$y_k = w_k + v_k$$
$$\hat{y}_k = w_k + v_k - e_k$$

Además $Bu = Fw$, y por lo tanto:

$$w_k = b_1 u_{k-1} + b_2 u_{k-2} + \ldots - f_1 w_{k-1} - f_2 w_{k-2} - \ldots$$

Por otro lado $Ce = Dv$ resultando:

$$v_k = e_k + c_1 e_{k-1} + \ldots - d_1 v_{k-1} - d_2 v_{k-2} - \ldots$$

Reemplazando w_k y v_k en la expresión del predictor se tiene:

$$\hat{y}_k = b_1 u_{k-1} + b_2 u_{k-2} + \ldots - f_1 w_{k-1} - f_2 w_{k-2} - \ldots + \cancel{e_k} + c_1 e_{k-1} + \ldots - d_1 v_{k-1} - d_2 v_{k-2} - \ldots - \cancel{e_k}$$

↳ muy conveniente para el avance de la trama

De alguna manera tenemos q' incrementar w_k y v_k

Dada la ecuación del predictor

$$\hat{y}_k = b_1 u_{k-1} + \ldots - f_1 w_{k-1} - \ldots + c_1 e_{k-1} + \ldots - d_1 v_{k-1} - \ldots = \varphi_k^\top \theta_k$$

Se reinterpretan los vectores de RLS según:

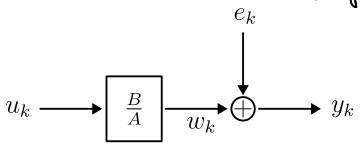
$$\varphi_k^\top = \begin{bmatrix} u_{k-1} & \ldots & -w_{k-1} & \ldots & e_{k-1} & \ldots & -v_{k-1} & \ldots \end{bmatrix}$$
$$\theta_k^\top = \begin{bmatrix} b_1 & \ldots & f_1 & \ldots & c_1 & \ldots & d_1 & \ldots \end{bmatrix}$$

Con las siguientes variables auxiliares construidas a partir de mediciones y estimaciones

$$w_k = b_1 u_{k-1} + \ldots - f_1 w_{k-1} - \ldots$$
$$v_k = y_k - w_k$$
$$e_k = y_k - \varphi_k^\top \theta_k$$

Uno espetaría q' esto fuera lo más cercano a la realidad

$A\,y_n = B\,u_n + A\,e_k$ ruido coloreado



$$y_k = \frac{B}{A}u_k + e_k$$

- Hasta aquí se modelaron perturbaciones dadas por error de ecuación.
- OE busca modelar una perturbación RB que afecta a la medición

Dada la ecuación de la planta, el predictor difiere solo en RB,

$$y_k = \frac{B}{A} u_k + e_k$$
$$\hat{y}_k = \frac{\hat{B}}{\hat{A}} u_k$$

Expresado en la forma del predictor resulta:

$$\hat{A}\,\hat{y}_k = \hat{B}\,u_k$$
$$\hat{y}_k = \hat{a}_1 \hat{y}_{k-1} + \ldots + \hat{b}_1 u_{k-1} + \ldots$$

Lo que permite reinterpretar los vectores de RLS, notando que en realidad el problema es **no lineal**

$$\varphi_k^\top = \begin{bmatrix} \hat{y}_{k-1} & \ldots & u_{k-1} \end{bmatrix}$$
$$\theta_k^\top = \begin{bmatrix} \hat{a}_1 & \ldots & \hat{b}_1 & \ldots \end{bmatrix}$$

Consideraciones:

- En el modelo OE, el funcional $J = \sum e_k^2$ es no lineal en θ , por lo que RLS es no consistente
- Se puede linealizar con una aproximación de 1° orden

$$e(k, \theta + \Delta\theta) \sim e(k, \theta) - \frac{\partial \hat{y}}{\partial \theta}^\top \Delta\theta$$

- Se define el vector de sensibilidades: $\varphi_k^\top = \frac{\partial \hat{y}}{\partial \theta}$

Luego, el funcional se expresa en términos del vector de sensibilidades y resulta un problema lineal en $\Delta\theta$

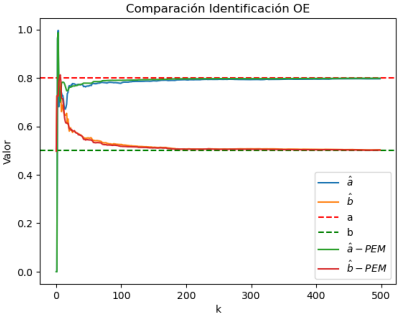
$$J(\theta + \Delta\theta) \sim \sum [e(k, \theta) - \varphi_k^\top \Delta\theta]^2$$

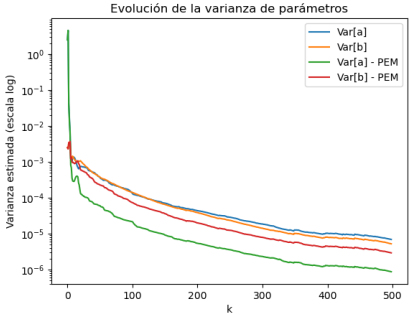
¿Inicialización?
→ Es mala idea arrancar en 0.

$$\frac{\partial \hat{y}_k}{\partial \hat{a}_i} = s_{a_i}(k) = \hat{y}_{k-i} + a_i s_{a_i}(k-i)$$

$$\frac{\partial \hat{y}_k}{\partial \hat{b}_i} = s_{b_i}(k) = u_{k-i} + b_i s_{b_i}(k-i)$$

$$y_k = \frac{B}{A} u_k + e_k$$





Ver notebook con el ejemplo



Resumen de modelos

Caballito de batalla.

Modelo	Qué estima	Residuo	Uso típico
ARX	Planta	No corrige perturbación	Control clásico, rápido
ARMAX	Planta + ruido	Residuo decorrelacionado	Mejora predicción
BJ	Planta + ruido	Residuo decorrelacionado, estructura más flexible	Identificación precisa
OE	Planta con perturbación en medición	Modela perturbación en la salida	Modelado cuando el ruido no afecta la dinámica

IDEA PARA LA ID PARAMÉTRICA: DEJAR EL INTEGRADOR DE LADO, YA SABEMOS QUE ESTÁ
Derivar la entrada o la salida? --> La salida ¿Y el rudio? No está correlacionado. ¿Molesta tanto derivar el ruido?
PROBAR. Ver el código 'identificacion_derivador.m'

Ver el código 'identificacion_reducida.m'

Reducir el orden del sistema identificado. Es más complejo que tachar polos con ceros
Valores singulares de Hanckel? Diagonalización? Matrices Wc y Wo? Gramianos de controlabilidad y observabilidad?
Qué direcciones son excitables y qué direcciones son relevantes para la salida? Las que no sean se tienen que filtrar
funciones dbalreal y dmodred

No es lo mismo que identificar directamente con un modelo de orden menor.