Identificación y Control Adaptativo
Identificación paramétrica

Pablo Gonzalez

FIUBA

Nota sobre las simulaciones que dieron mal:
Restar la media?

OTRA IDEA: Identificar solo la transferencia barra-carro, total la otra la conocemos

2026

1 INTRODUCCIÓN
2 MODELO DE REGRESIÓN
3 IDENTIFICACIÓN POR MÍNIMOS CUADRADOS
4 MÍNIMOS CUADRADOS RECURSIVOS
5 CONDICIONES EXPERIMENTALES
6 ESTRUCTURA DEL MODELO
7 VALIDACIÓN DEL MODELO



¿Qué significa identificar un sistema?

- Tenemos datos medidos de entrada y salida.
- Queremos construir un modelo que reproduzca la dinámica observada.
- Los parámetros del modelo son desconocidos y deben estimarse.



Idea central

No partimos necesariamente de las ecuaciones físicas del sistema:

- proponemos una estructura del modelo
- y aprendemos sus parámetros a partir de datos.

1 INTRODUCCIÓN

2 MODELO DE REGRESIÓN

3 IDENTIFICACIÓN POR MÍNIMOS CUADRADOS

4 MÍNIMOS CUADRADOS RECURSIVOS

5 CONDICIONES EXPERIMENTALES

6 ESTRUCTURA DEL MODELO

7 VALIDACIÓN DEL MODELO

Supongamos un modelo lineal en los parámetros. Se puede escribir:

$$y_k = \varphi_k^\top \theta + e_k$$

donde

- y_k: salida medida,
- φ_k: vector de regresores conocidos,
- θ: parámetros desconocidos,
- e_k: error de modelado + ruido.

Para muchos modelos dinámicos, los regresores contienen muestras pasadas:

$$\varphi_k = \begin{bmatrix} y_{k-1} & \cdots & y_{k-n} & u_{k-1} & \cdots & u_{k-m} \end{bmatrix}^\top$$

Se tiene un modelo lineal de segundo orden de tipo ARX:

$$A(q)y_k = B(q)u_k + e_k$$

Se lleva a la forma de predicción, $A(q) = 1 - a_1 q^{-1} - a_2 q^{-2}$

$$y_k = a_1 y_{k-1} + a_2 y_{k-2} + b_1 u_{k-1} + b_2 u_{k-2} + e_k \qquad e_k \perp y_{k-1}$$

y factorizando los parámetros, queda en la forma de regresión

$$y_k = \underbrace{\begin{bmatrix} y_{k-1} & y_{k-2} & u_{k-1} & u_{k-2} \end{bmatrix}}_{\varphi_k^\top} \underbrace{\begin{bmatrix} a_1 \\ a_2 \\ b_1 \\ b_2 \end{bmatrix}}_{\theta} + e_k$$

Consideremos un péndulo simple:

$$J\ddot{y}(t) + b\dot{y}(t) + mgl\sin(y(t)) = \tau(t)$$

Se puede proponer un modelo discreto con la siguiente estructura:

$$y_k = \theta_1 y_{k-1} + \theta_2 y_{k-2} + \theta_3 \sin(y_{k-1}) + \theta_4 u_{k-1} + e_k$$

↳ hasta derivada segunda

y llevarlo a la forma de regresión

$$y_k = \underbrace{\begin{bmatrix} y_{k-1} & y_{k-2} & \sin(y_{k-1}) & u_{k-1} \end{bmatrix}}_{\varphi_k^\top} \underbrace{\begin{bmatrix} \theta_1 \\ \theta_2 \\ \theta_3 \\ \theta_4 \end{bmatrix}}_{\theta} + e_k$$

El modelo puede ser **no lineal en las señales** y aún llevarlo a la forma de regresión

Con k observaciones, vectorizamos las ecuaciones:

$$Y_k = \Phi_k \theta + E_k$$

Para un modelo ARX de grado n, las matrices resultan

$$Y_k = \begin{bmatrix} y_k \\ \vdots \\ y_1 \end{bmatrix} \qquad \Phi_k = \begin{bmatrix} y_{k-1} & \cdots & y_{k-n} & u_{k-1} & \cdots & u_{k-m} \\ \vdots & & \vdots & \vdots & & \vdots \\ y_0 & \cdots & y_{1-n} & u_0 & \cdots & u_{1-m} \end{bmatrix} \qquad \theta = \begin{bmatrix} a_1 \\ \vdots \\ a_n \\ b_1 \\ \vdots \\ b_m \end{bmatrix} \qquad E_k = \begin{bmatrix} e_k \\ \vdots \\ e_1 \end{bmatrix}$$



Trayecto

1. Introducción
2. Modelo de regresión
3. Identificación por mínimos cuadrados
4. Mínimos cuadrados recursivos
5. Condiciones experimentales
6. Estructura del modelo
7. Validación del modelo

Sea la estimación $\hat{\theta}$, hasta el instante k se tendrá un error dado por el vector

$$E_k = Y_k - \Phi_k \hat{\theta}$$

El acumulado en las k mediciones del error cuadrático de la estimación resulta

$$J_k(\hat{\theta}) = E_k^\top E_k = (Y_k - \Phi_k \hat{\theta})^\top (Y_k - \Phi_k \hat{\theta}) = Y_k^\top Y_k + \hat{\theta}^\top \Phi_k^\top \Phi_k \hat{\theta} - 2\hat{\theta}^\top \Phi_k^\top Y_k$$

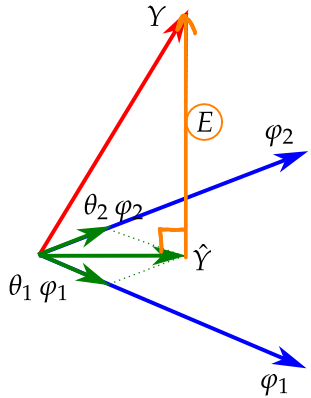
En el mínimo de la función de costo se tiene que el gradiente se anula

$$\nabla_\theta J|_{\hat{\theta}} = 2\Phi_k^\top \Phi_k \hat{\theta} - 2\Phi_k^\top Y_k = 0$$

Despejando $\hat{\theta}_k$ se llega a la solución analítica del problema de estimación por LS

$$\boxed{\hat{\theta}_k = \left(\Phi_k^\top \Phi_k\right)^{-1} \Phi_k^\top Y_k}$$

$\Phi_k^\top \Phi_k$ es invertible cuando la información en los datos permite distinguir los distintos parámetros



filas

- Las columnas de Φ generan un subespacio
- θ expresa las coordenadas de la estimación en ese espacio.
- $\hat{Y}$ está en el span de Φ
- E resulta ortogonal a $\hat{Y}$ cuando es mínimo

$$\varphi^\top E = 0$$

¿En castellano?

Identificar es encontrar la combinación de regresores que mejor explica las observaciones.

Supongamos que:

- θ son los parámetros *verdaderos*, y la estimación $\hat{\theta}$ es una variable aleatoria
- E es ruido blanco con varianza σ^2 e independiente de Φ

La esperanza de la estimación resulta

Premultiplica x' la P.I.

$$Y = \Phi\theta + E$$

$$\left(\Phi^\top\Phi\right)^{-1}\Phi^\top Y = \left(\Phi^\top\Phi\right)^{-1}\Phi^\top\Phi\theta + \left(\Phi^\top\Phi\right)^{-1}\Phi^\top E$$

$$\hat{\theta} = \theta + \left(\Phi^\top\Phi\right)^{-1}\Phi^\top E$$

$$\mathbb{E}\left[\hat{\theta}\right] = \theta + \mathbb{E}\left[\left(\Phi^\top\Phi\right)^{-1}\Phi^\top E\right]$$

→ E es indep de Φ x_q'
Φ tiene cosas de y_k y y_K

Bajo estas condiciones el estimador por LS para un modelo ARX es **insesgado**: $\mathbb{E}\left[\hat{\theta}\right] = \theta$

matriz de covariancia o matriz de información

$$\Phi_k^\top \Phi_k = \begin{bmatrix} y_{k-1} & \cdots & y_0 \\ \vdots & & \vdots \\ y_{k-n} & \cdots & y_{1-n} \\ u_{k-1} & \cdots & u_0 \\ \vdots & & \vdots \\ u_{k-m} & \cdots & u_{1-m} \end{bmatrix} \cdot \begin{bmatrix} y_{k-1} & \cdots & y_{k-n} & u_{k-1} & \cdots & u_{k-m} \\ \vdots & & \vdots & \vdots & & \vdots \\ y_0 & \cdots & y_{1-n} & u_0 & \cdots & u_{1-m} \end{bmatrix}$$

Lo podemos llamar covariancia si la media es nula

media nula

medialuna

$$\Phi_k^\top \Phi_k = \begin{bmatrix} r_y(0) & \cdots & r_y(n-1) & r_{yu}(0) & \cdots & r_{yu}(m-1) \\ \vdots & & \vdots & \vdots & & \vdots \\ r_y(n-1) & \cdots & r_y(0) & r_{yu}(n-1) & \cdots & r_{yu}(n-m) \\ r_{yu}(0) & \cdots & r_{yu}(n-1) & r_u(0) & \cdots & r_u(m-1) \\ \vdots & & \vdots & \vdots & & \vdots \\ r_{yu}(m-1) & \cdots & r_{yu}(n-m) & r_u(m-1) & \cdots & r_u(0) \end{bmatrix}$$

$$\Phi^\top \cdot \Phi = \left[\begin{array}{c|c} R_{yy} & R_{yu} \\ \hline R_{uy} & R_{uu} \end{array}\right]$$

Esta matriz cuenta de cuánta información hay

La **matriz de covarianza** ($\Phi^T\Phi$) representa la *cantidad de información* contenida en los datos

Para el modelo ARX sobre el que venimos trabajando

$$A(q)y_k = B(q)u_k + e_k$$

con $\deg A = n$, $\deg B = m$ y retardo $d = n - m$, el regresor resulta:

$$\varphi_k^\top = \begin{bmatrix} y_{k-1} & \cdots & y_{k-n} & u_{k-d} & \cdots & u_{k-d-m+1} \end{bmatrix}.$$

Por lo tanto,

$$\Phi^\top \Phi = \begin{bmatrix} R_{yy} & R_{yu} \\ R_{uy} & R_{uu} \end{bmatrix}$$

Donde los bloques diagonales contienen autocorrelaciones, mientras que los bloques cruzados incorporan el **retardo relativo** d:

$$R_{yy} \sim r_y(\ell) \qquad R_{uu} \sim r_u(\ell) \qquad R_{yu} \sim r_{yu}(d + \ell)$$

Sabemos que

$$\hat{\theta} = \theta + \left(\Phi^\top \Phi\right)^{-1} \Phi^\top E$$

Por lo tanto la covarianza del estimador resulta

$$\begin{aligned} \operatorname{cov}(\hat{\theta}) &= \mathbb{E}\left[\left(\hat{\theta}-\theta\right)\left(\hat{\theta}-\theta\right)^\top\right] \\ &= \mathbb{E}\left\{\left(\Phi^\top \Phi\right)^{-1} \Phi^\top E E^\top \Phi \left(\Phi^\top \Phi\right)^{-1}\right\} \\ &= \sigma^2 \left(\Phi^\top \Phi\right)^{-1} \end{aligned}$$

$\mathbb{E}[E.E^T] = \sigma^2 I$ ← $= \sigma^2 I$

matriz de incertidumbre

La **precisión del estimador** (medida como la inversa de la varianza) se ve afectada por:

- **Nivel de Ruido** (σ^2). A mayor ruido en las mediciones, mayor será la dispersión de los parámetros estimados
- **Matriz de Información** ($\Phi^T\Phi$). A medida que la entrada es más excitante y $N \to \infty$, los valores propios de $\Phi^T\Phi$ crecen, haciendo que $(\Phi^T\Phi)^{-1}$ sea más pequeña.

- Un estimador $\hat{\theta}$ es consistente si converge en probabilidad o en media cuadrática al valor verdadero del parámetro (θ) a medida que el número de muestras N tiende a infinito ($N \to \infty$)

$$\text{MSE}(\hat{\theta}) = E\{||\hat{\theta} - \theta||^2\} = ||\Delta(\hat{\theta})||^2 + \text{trace}(\text{cov}(\hat{\theta}))$$

- Dado que el estimador es insesgado el término de sesgo se anula. Por lo tanto, el error depende únicamente de la varianza:

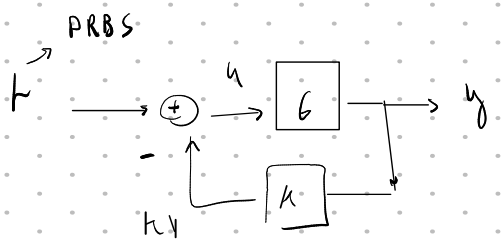
$$\text{MSE}(\hat{\theta}) = \text{trace}(\text{cov}(\hat{\theta}))$$

- Al sumar muestras con señales persistentemente excitadoras $(\Phi^T\Phi)^{-1} \to 0$ y por lo tanto $\text{cov}(\hat{\theta}) \to 0$ cuando $N \to \infty$
- Se cumple así $\text{MSE}(\hat{\theta}) \to 0$. Esto asegura la convergencia en media cuadrática (lo que implica convergencia en probabilidad), demostrando que **el estimador por LS para un modelo ARX es consistente**

Acá vimos el código 'ejemplo_identificacion_LS.m'

Añadir muchas muestras no agrega información si no hay ruido.

Un pulso no es suficente información para identificar un sistema de segundo orden.
Se necesita una excitación que dure más de una muestra si la dinámica es de segundo orden.



$$U/R = ?$$

$$U = R - KY = R - KG \cdot U$$

$$(1 + KG)U = R$$

$$U/R = \frac{1}{KG + 1}$$

- Sistema de primer orden $y_k = 0{,}5y_{k-1} + u_{k-1}$
  - Entrada impulso ✓
  - Entrada escalón ✓
- Sistema de segundo orden $y_k = 1{,}2y_{k-1} - 0{,}32y_{k-2} + u_{k-1}$
  - Entrada impulso: rango de $\Phi = 2$ ✗
  - Entrada escalón ✓

Ver ejemplo en Matlab

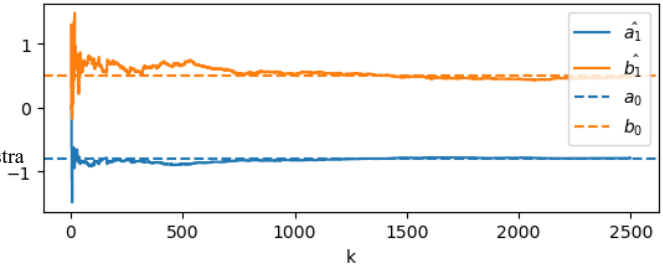
1 INTRODUCCIÓN
2 MODELO DE REGRESIÓN
3 IDENTIFICACIÓN POR MÍNIMOS CUADRADOS
4 MÍNIMOS CUADRADOS RECURSIVOS
5 CONDICIONES EXPERIMENTALES
6 ESTRUCTURA DEL MODELO
7 VALIDACIÓN DEL MODELO



- En aplicaciones como el control adaptativo, los datos llegan secuencialmente.
- Recalcular la solución de mínimos cuadrados completa en cada instante es ineficiente.
- Los algoritmos recursivos evitan este recálculo.
- En cada paso, actualizan la estimación anterior con la nueva información.
- Por lo que permite ajustar modelos ante dinámicas cambiantes o desconocidas.

$$\theta = \left(\Phi^t \cdot \Phi\right)^{-1} \Phi^t \cdot y_k$$

Hacer esta cuenta con cada muestra nueva sería ineficiente



Definamos la matriz de incertidumbre P_k como la inversa de la matriz de covarianza

$$P_k^{-1} = \Phi_k^\top \Phi_k = \begin{bmatrix} \varphi_k & \dots & \varphi_0 \end{bmatrix} \begin{bmatrix} \varphi_k^\top \\ \vdots \\ \varphi_0^\top \end{bmatrix} = \sum_{i=0}^{k} \varphi_i \varphi_i^\top = P_{k-1}^{-1} + \varphi_k \varphi_k^\top \rightarrow \text{expresión recursiva}$$

$P_k^{-1} \in \mathbb{R}^{r \times r}$ donde r es la cantidad de regresores

Luego el vector b_k

La dimensión de phi crece con cada muestra
La dimensión de P NO.

$$b_k = \Phi_k^\top Y_k = \begin{bmatrix} \varphi_k & \dots & \varphi_0 \end{bmatrix} \begin{bmatrix} y_k \\ \vdots \\ y_0 \end{bmatrix} = \sum_{i=0}^{k} \varphi_i y_i = b_{k-1} + \varphi_k y_k \rightarrow \text{expresión recursiva}$$

Con estas definiciones el estimador por mínimos cuadrados resulta:

$$\hat{\theta}_k = \underbrace{\left(\Phi_k^\top \Phi_k\right)^{-1}}_{P_k} \underbrace{\Phi_k^\top Y_k}_{b_k} = P_k\, b_k$$

La inversa de P_k puede expresarse en función de su valor anterior más otra matriz que aporta la *novedad*.

$$P_k^{-1} = P_{k-1}^{-1} + \varphi_k \varphi_k^\top \;\Rightarrow\; P_k P_k^{-1} P_{k-1} = P_k P_{k-1}^{-1} P_{k-1} + P_k \varphi_k \varphi_k^\top P_{k-1} \;\Rightarrow\; P_{k-1} = P_k + P_k \varphi_k \varphi_k^\top P_{k-1}$$

reemplazar acá

Aun debemos dejar P_k en función de P_{k-1} y los datos nuevos. Si posmultiplicamos por φ_k:

$$P_{k-1}\varphi_k = P_k\varphi_k + P_k\varphi_k\varphi_k^\top P_{k-1}\varphi_k = P_k\varphi_k \left[1 + \varphi_k^\top P_{k-1}\varphi_k\right] \quad\Rightarrow\quad P_{k-1}\varphi_k \left[1 + \varphi_k^\top P_{k-1}\varphi_k\right]^{-1} = P_k\varphi_k$$

De las dos ecuaciones anteriores encontramos la expresión en recurrencia para P_k

$$P_k = P_{k-1} - \frac{P_{k-1}\varphi_k\varphi_k^\top P_{k-1}}{1 + \varphi_k^\top P_{k-1}\varphi_k}$$

Siempre se resta, la incertidumbre disminuye

$P_k^{-1} = \Phi^t \Phi$

$\left(P_k^{-1}\right)^t = \Phi^t \Phi = P_k^{-1}$

$\therefore P_k = P_k^t$, P_k simétrica

$\chi = P_{k-1} \cdot \varphi_k \qquad \chi^t = \varphi_k^t \cdot P_{k-1}$

Esto se puede interpretar de forma geométrica. La única verdad es la realidad y la única realidad es la geometría

¿ Y con todo esto qué onda?

$$x \cdot x^T = A \qquad \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} (x_1\ x_2\ x_3) = \begin{pmatrix} x_1(x_1\ x_2\ x_3) \\ x_2(x_1\ x_2\ x_3) \\ x_3(x_1\ x_2\ x_3) \end{pmatrix}$$

↓

Las filas son múltiplos. Las 3 filas son colineales

Otra forma de verlo:

$(x \cdot x^t) \cdot x = x \cdot \|x\|^2 \rightarrow x$ es ave de A

Sea $y \perp x$: $x \cdot x^t \cdot y = 0 \Rightarrow y \in N_u(A)$. Si $x \in \mathbb{R}^N$ hay $N-1$ vectores y

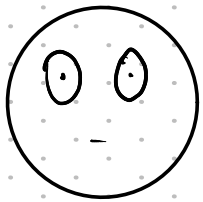
$\Rightarrow \dim(N_u(A)) = N-1 \Rightarrow$ A de rango 1

A comprime el espacio en una recta

y definimos $x = P_K \cdot \varphi_K$

La matriz $P_K \varphi_K \cdot \varphi_K^t \cdot P_K^t = x \cdot x^t$ define una dirección

En esta dirección se resta la incertidumbre



- P_{k-1} representa la incertidumbre que tenemos antes de incorporar la nueva observación.
- φ_k: representa la nueva dirección de información que aporta la observación.
- $P_{k-1}\varphi_k$: proyecta esa nueva información sobre la geometría de nuestra incertidumbre. **Indica en qué dirección podemos reducir la incertidumbre**.
- $(P_{k-1}\varphi_k)(P_{k-1}\varphi_k)^\top$: concentra el recorte de incertidumbre en esa dirección.
- $\varphi_k^\top P_{k-1}\varphi_k$: mide cuánta incertidumbre tenemos asociada a esa nueva dirección.
- $1 + \varphi_k^\top P_{k-1}\varphi_k$: regula la magnitud del recorte. La reducción se adapta a la incertidumbre disponible en esa dirección.

Por ejemplo:

- Si $P_{k-1}\varphi_k \approx 0$: la nueva observación aporta poca información útil y $P_k \approx P_{k-1}$.
- Si $P_{k-1}\varphi_k$ es grande: la observación incide sobre una dirección donde todavía hay bastante incertidumbre y el recorte es mayor.

RLS actualiza la incertidumbre recortándola en las direcciones donde la nueva observación aporta información.

Reemplazando la fórmula de recurrencia de P_k y b_k en la expresión de la estimación de los parámetros:

$$\hat{\theta}_k = P_k\, b_k = \left[P_{k-1} - \frac{P_{k-1}\varphi_k\varphi_k^\top P_{k-1}}{1+\varphi_k^\top P_{k-1}\varphi_k}\right][b_{k-1} + \varphi_k y_k]$$

$$\hat{\theta}_k = \hat{\theta}_{k-1} - \frac{P_{k-1}\varphi_k\varphi_k^\top P_{k-1}}{1+\varphi_k^\top P_{k-1}\varphi_k}[b_{k-1} + \varphi_k y_k] + P_{k-1}\varphi_k y_k$$

$$\hat{\theta}_k = \hat{\theta}_{k-1} - P_k\varphi_k\varphi_k^\top P_{k-1}[b_{k-1} + \varphi_k y_k] + P_{k-1}\varphi_k y_k$$

$$\hat{\theta}_k = \hat{\theta}_{k-1} - P_k\varphi_k\varphi_k^\top \hat{\theta}_{k-1} + \left[P_{k-1} - P_k\varphi_k\varphi_k^\top P_{k-1}\right]\varphi_k y_k$$

$$\hat{\theta}_k = \hat{\theta}_{k-1} - P_k\varphi_k\varphi_k^\top \hat{\theta}_{k-1} + P_k\varphi_k y_k$$

$$\boxed{\hat{\theta}_k = \hat{\theta}_{k-1} - P_k\varphi_k\left[\varphi_k^\top\hat{\theta}_{k-1} - y_k\right]}$$

"VAINILLA"

La estimación se corrige en la dirección de la nueva información, escalada por el error de predicción.

Si definimos

$$K_{k-1} = \frac{P_{k-1}\varphi_k}{1 + \varphi_k^\top P_{k-1}\varphi_k}$$

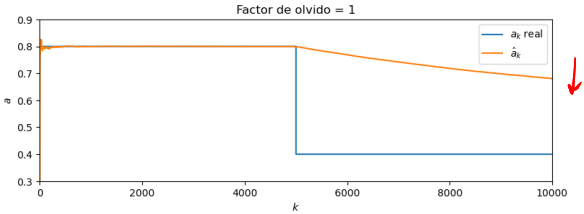
Podemos expresar las ecuaciones de actualización de incertidumbre y parámetros como:

$$P_k = P_{k-1} - K_{k-1}\varphi_k^\top P_{k-1}$$
$$\hat{\theta}_k = \hat{\theta}_{k-1} + K_{k-1}\left[y_k - \hat{y}_k\right]$$

- K_k: actúa como una **ganancia de Kalman**, determinando cuánto y en qué dirección corregir la estimación.
- $y_k - \hat{y}_k$: es la **innovación**, es decir, la información nueva que surge de comparar la medición con la predicción.
- P_k: actualiza la **incertidumbre de los parámetros**, reduciéndola según la información aportada por la nueva observación.

Hay que dejar ir

- En el estimador anterior, todas las muestras tienen el mismo peso. Si los parámetros del sistema varían con el tiempo, las muestras antiguas pueden dejar de ser representativas del sistema actual

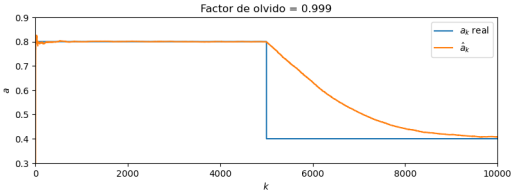


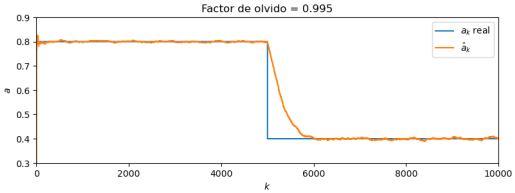
↓ No baja nunca

- Se introduce un **factor de olvido** $0 < \lambda \leq 1$, que pondera las muestras según su antigüedad

$$1, \quad \lambda, \quad \lambda^2, \quad \lambda^3, \ldots$$

- De este modo, las observaciones tienen una influencia que decrece exponencialmente con el tiempo.





+RUIDO. El ruido es el precio a pagar

El valor de λ establece un compromiso:

- $\lambda \approx 1$: mayor memoria y seguimiento más suave.
- $\lambda \searrow$: menor memoria y adaptación más rápida, pero mayor sensibilidad al ruido.

Se redefine la función de costo a minimizar

La matriz KUKA

$$J_k(\hat{\theta}) = E_k^\top Q_k E_k \qquad Q_n = \begin{bmatrix} 1 & \lambda & \lambda^2 \cdots & 0 \\ 0 & & & \lambda^n \end{bmatrix}$$

donde Q es una matriz diagonal que marca una progresión exponencial λ^k. Igualando a cero el gradiente:

$$\nabla_\theta J|_{\hat{\theta}} = 2\Phi_k^\top Q_k \Phi_k \hat{\theta} - 2\Phi_k^\top Q_k Y_k = 0$$

Se despeja $\hat{\theta}_k$,

$$\hat{\theta}_k = \left(\Phi_k^\top Q_k \Phi_k\right)^{-1} \Phi_k^\top Q_k Y_k$$

O en forma recursiva,

$$P_k = \frac{1}{\lambda}\left[P_{k-1} - \frac{P_{k-1}\varphi_k\varphi_k^\top P_{k-1}}{\lambda + \varphi_k^\top P_{k-1}\varphi_k}\right]$$

$$\hat{\theta}_k = \hat{\theta}_{k-1} - P_k\varphi_k\left[\hat{y}_k - y_k\right]$$





Trayecto

1. Introducción
2. Modelo de regresión
3. Identificación por mínimos cuadrados
4. Mínimos cuadrados recursivos
5. Condiciones experimentales
6. Estructura del modelo
7. Validación del modelo

El ruido blanco gaussiano es PE de orden ∞

- Para que el estimador LS determine una solución única, se requiere $\Phi^\top \Phi$ invertible. Es decir, que las señales regresoras **aporten información independiente**.
- Esta condición sobre los datos se formaliza mediante la **Excitación Persistente (PE)**.
- Una señal u_k es PE de orden n si la matriz de covarianza C_n es definida positiva

$$C_n \succ 0 \iff \|\Phi x\|^2 > 0 \quad \forall x \neq 0 \iff \operatorname{rank}(\Phi) = n$$

- **Interpretación:** la entrada debe explorar suficientemente distintas direcciones del espacio de regresores.
- Para estimar un modelo con p parámetros, se requiere excitación persistente de orden suficiente para que las p direcciones puedan distinguirse.

ver el notebook 'identificacion_parametrica.ipynb'
El orden de la excitación indica cuántos parámetros puedo identificar.

$$\frac{\theta_b}{\theta_s} = \frac{K}{(s+p_1)(s+p_2)} = \frac{K}{s^2+(p_1+p_2)s+p_1 \cdot p_2} = \frac{Y}{U}$$

$$Y\left(s^2+(p_1+p_2)s+p_1 \cdot p_2\right) = K \cdot U$$

$$\ddot{y} + (p_1+p_2)\dot{y} + p_1 \cdot p_2\, y = K u$$

$$\rightarrow y_k = a_1 y_{k-1} + a_2 y_{k-2} + b_1 u_{k-1}$$

El sistema a identificar será:

$$y_k = a_1 y_{k-1} + a_2 y_{k-2} + b_1 u_{k-1} + e_k$$

Tipo de Señal	Orden Máximo de PE	Comentario
Pulso	0	No es PE de ningún orden.
Escalón	1	Solo puede identificar un parámetro (p.ej., la ganancia estática).
Senoide pura	2	Puede identificar hasta dos parámetros.
Suma de k sinusoides	$2k$	El orden aumenta con la riqueza espectral.
Secuencia PRBS	Muy alto	Buena elección para identificación, ya que su espectro es casi plano.
Ruido blanco	Infinito	Es excitante de cualquier orden.

Ver ejemplo ahora vimos ejemplo_pipeline_identificacion.m

conjunto de testeo: sacar métricas del modelo
validación: sacar hiperparámetros.

La velocidad con la que la varianza del estimador converge a cero depende del comportamiento asintótico de los regresores.

- Si los regresores son acotados (ej: entrada PRBS), la varianza decrece como $1/N$.
- Si los regresores decrecen muy rápido (ej: entrada pulso), la varianza puede no converger a cero.
- Si los regresores crecen con el tiempo, la varianza converge a cero más rápidamente.

Para que LS sea insesgado se requiere que el ruido sea incorrelacionado con los regresores:

$$\mathbb{E}\{\varphi_k\, e_k\} = 0.$$

En modelos con dinámica del ruido, como ARMAX, esta condición puede violarse porque las salidas pasadas pertenecen al vector de regresores

¿Cómo evitar el sesgo?

- **Mínimos Cuadrados Extendidos ELS:** incorpora estimaciones del ruido pasado al vector de regresores.
- **Variables Instrumentales (IV):** utiliza variables correlacionadas con los regresores, pero incorrelacionadas con el ruido.
- **Máxima Verosimilitud (ML):** estima los parámetros buscando maximizar la probabilidad de los datos observados bajo un modelo estadístico del ruido.

Cuando el sistema opera en lazo cerrado, entrada y salida dejan de ser independientes. Por ejemplo,

$$u_k = -K y_k$$

introduce una dependencia entre las señales que forman los regresores. Esto puede reducir el rango de Φ y provocar una pérdida de identificabilidad: $\text{rank}(\Phi) < n \quad \Longrightarrow \quad \Phi^\top \Phi$ singular

¿Cómo recuperar la identificabilidad?

- **Regulador dinámico:** una estructura de orden suficiente puede evitar la dependencia lineal simple entre entrada y salida.
- **Ganancia variable:** si el controlador cambia con el tiempo, se generan nuevas direcciones de información.
- **Excitación externa:** una referencia $r(k)$ persistentemente excitante aporta información independiente.

Recuperar la identificabilidad no implica necesariamente una convergencia rápida: la estimación puede acercarse rápidamente al subespacio identificable y evolucionar lentamente en las direcciones restantes.

1. Introducción
2. Modelo de regresión
3. Identificación por mínimos cuadrados
4. Mínimos cuadrados recursivos
5. Condiciones experimentales
6. Estructura del modelo
7. Validación del modelo

- La identificación no termina con la estimación de los parámetros: también debemos elegir una **estructura de modelo** adecuada.
- La complejidad del modelo debe ser suficiente para capturar la dinámica relevante, pero sin incorporar el ruido de los datos.
- **Subajuste:** modelo demasiado simple.
  - No captura toda la dinámica del sistema.
  - Presenta errores sistemáticos en los datos.
- **Sobreajuste:** modelo demasiado complejo.
  - Se adapta muy bien a los datos utilizados para identificarlo.
  - Puede terminar modelando ruido en lugar de dinámica.
  - Su capacidad predictiva puede deteriorarse con datos nuevos.

Complejidad insuficiente $\longleftrightarrow$ Complejidad excesiva

- Para una misma estructura pueden considerarse distintos órdenes de los polinomios.
- Los criterios de selección buscan un compromiso entre **calidad del ajuste** y **complejidad del modelo**.
- Se evalúa el criterio para distintos órdenes y se selecciona el que **lo minimiza**.
- El **test F** permite evaluar si agregar parámetros produce una mejora estadísticamente significativa.

$\hat{\sigma}^2$: MSE

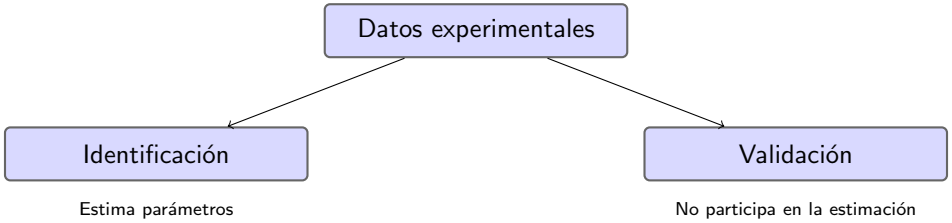
Criterio	Idea Principal	Fórmula
Error de Predicción Final	Error de predicción esperado en datos nuevos	$\text{FPE} = \hat{\sigma}^2 \frac{N+p}{N-p}$
Criterio de Información de Akaike	Ajuste + penalización por complejidad	$\text{AIC} = \log(\hat{\sigma}^2) + \frac{2p}{N}$
Longitud Mínima de Descripción	Ajuste + penalización más fuerte por complejidad	$\text{MDL} = \log(\hat{\sigma}^2) + \frac{p \log(N)}{N}$

N: datos
p: parámetros

Los polos y ceros se pisan: complejidad excesiva.

1. Introducción
2. Modelo de regresión
3. Identificación por mínimos cuadrados
4. Mínimos cuadrados recursivos
5. Condiciones experimentales
6. Estructura del modelo
7. Validación del modelo

- Los datos experimentales se dividen en dos conjuntos:
  - **Identificación:** utilizados para estimar los parámetros del modelo.
  - **Validación:** no utilizados durante la estimación.
- Una vez identificado el modelo, el conjunto de validación permite evaluar su comportamiento sobre datos que no utilizó para ajustarse.



La validación debe utilizar información independiente de la estimación



Ubicación de polos y ceros

- Los experimentos preliminares y los modelos no paramétricos permiten obtener una idea inicial de la ubicación de polos y ceros.
- Se verifica que la ubicación obtenida en el modelo paramétrico sea **coherente con la información previa**.
- También es importante analizar el **modelo del ruido**:
  - frecuencias predominantes en el ruido deberían reflejarse en polos resonantes del modelo.
- La representación de polos y ceros permite detectar posibles **problemas de complejidad del modelo**:
  - orden excesivamente elevado;
  - polos muy cercanos a ceros, que pueden sugerir una **reducción de orden**.



Evaluación del Modelo

Una vez estimado el modelo, podemos evaluarlo utilizando datos que no participaron en la identificación.

Predicción

Se utiliza información disponible hasta el instante k para predecir la salida:

$$y(k) \qquad \text{vs.} \qquad \hat{y}(k|k-1)$$

Permite evaluar la capacidad predictiva del modelo.

Simulación

Se aplica al modelo la misma entrada que al sistema:

$$y(k) \qquad \text{vs.} \qquad \hat{y}_{\text{sim}}(k)$$

Permite evaluar la reproducción de la dinámica del sistema.

¿Cuál utilizar?

Depende del propósito del modelo y del uso que se hará de él.

- Una vez estimado el modelo, definimos el residuo:

$$\epsilon(k) = y(k) - \hat{y}(k|\hat{\theta}).$$

- Si el modelo capturó adecuadamente la dinámica del sistema, los residuos deberían comportarse como **ruido blanco**: no deberían contener información predecible.
- **Un buen modelo deja residuos sin información predecible**. Se verifican principalmente dos condiciones:

Autocorrelación

$$R_{\epsilon\epsilon}(\tau) \approx \begin{cases} \sigma_\epsilon^2, & \tau = 0 \\ 0, & \tau \neq 0 \end{cases}$$

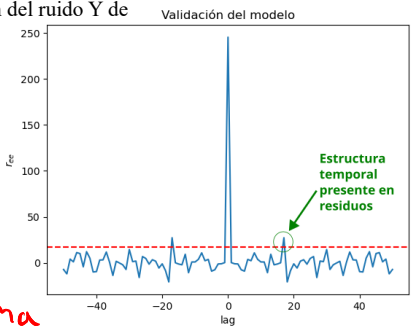
No debería quedar estructura temporal en los residuos.

Correlación con la entrada

$$R_{u\epsilon}(\tau) \approx 0$$

La entrada no debe contener información sobre el ruido.

si la autocor. del residuo excede al intervalo de confianza, el modelo no es lo suficientemente complejo, todavía hay información en el ruido. El residuo e tiene información del ruido Y de la discrepancia entre entrada y salida.



- En un conjunto finito de datos, el ruido blanco presenta correlaciones muestrales distintas de cero.
- Para residuos aproximadamente gaussianos e independientes, la autocorrelación normalizada cumple:

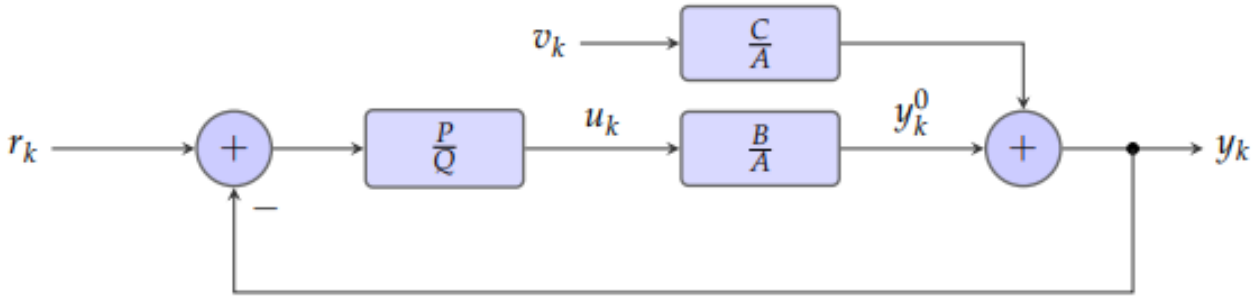
$$\frac{R_{\epsilon\epsilon}(i)}{R_{\epsilon\epsilon}(0)} \sim \mathcal{N}\left(0, \frac{1}{N}\right) \implies \left|\frac{R_{\epsilon\epsilon}(i)}{R_{\epsilon\epsilon}(0)}\right| < \frac{2{,}17}{\sqrt{N}} \quad (98{,}5\,\%)$$

$\pm 2{,}17\,\sigma \rightarrow 98{,}5\,\%$ del área de la gaussiana

- Si las autocorrelaciones están dentro de la banda, no hay evidencia fuerte de correlación temporal.
- Si aparecen valores fuera de la banda, puede existir información dinámica que el modelo no está capturando.

La prueba no busca autocorrelación exactamente nula: busca que las correlaciones sean compatibles con las fluctuaciones esperables en una muestra finita.

PÉRDIDA DE IDENTIFICABILIDAD



Cuando el sistema opera en lazo cerrado, entrada y salida dejan de ser independientes. Por ejemplo,

Para $t=0$ ← $u_k = -K y_k$ → en la matriz Φ quedan datos repetidos

introduce una dependencia entre las señales que forman los regresores.
Esto puede reducir el rango de Φ y provocar una pérdida de identificabilidad:

$$\text{rank}(\Phi) < n \implies \Phi^\top \Phi \text{ singular}$$

$u_k = -k y_k$

$$\Phi = \begin{pmatrix} y_k \cdots & u_k \cdots \\ \vdots & \vdots \end{pmatrix}$$

AMBIGÜEDAD ESTRUCTURAL

Consideremos $r = 0$ en el diagrama en bloques anterior.

$$Ay = Bu + Cv \qquad \left(Pu = -Qy\right) \rightarrow \text{regulador o controlador}$$

Al sumar una señal arbitraria Sy y reordenar:

$$Ay + Sy = Bu + Sy + Cv \qquad y = -\frac{P}{Q} \cdot u$$

$$(A+S)y = \left(B - S\frac{P}{Q}\right)u + Cv$$

$$\underbrace{(A+S)Q}_{A^*}\,y = \underbrace{(QB - PS)}_{B^*}\,u + \underbrace{CQ}_{C^*}\,v$$

PROBLEMA

Existe **ambigüedad estructural**: distintos (A^*, B^*, D^*) explican los mismos datos

- El regulador queda incorporado en la representación identificada.
- Conocer la **estructura y el orden** del sistema restringe las representaciones posibles y permite evitar el sesgo.

Seguimos con $r = 0$ y medimos $\{y, u\}$. Eliminemos v del modelo:

$$Ay = B\left(-\frac{Q}{P}y\right) + Cv \quad \Rightarrow \quad v = \frac{AP + BQ}{CP}y$$



Por lo tanto el modelo que solo relaciona y y u tiene la estructura:

$$Ay = Bu + C\frac{AP + BQ}{CP}y \quad \Rightarrow \quad \cancel{APy} = BPu + \cancel{APy} + BQy \quad \Rightarrow \quad Qy = -Pu$$

PROBLEMA

La relación entre u e y está determinada por el **regulador**. Por lo tanto, una identificación basada únicamente en estas dos señales puede recuperar y/u pero no permite identificar la dinámica del proceso.

No estamos identificando el sistema: estamos identificando el regulador.

Posibles soluciones



¿CÓMO RECUPERAR LA IDENTIFICABILIDAD?

.UBAfiuba FACULTAD DE INGENIERÍA

El objetivo es recuperar las direcciones de información perdidas:

- **Regulador dinámico:** una estructura de orden suficiente puede evitar la dependencia lineal simple entre entrada y salida. No usar un proporcional, sino algo más complejo
- **Ganancia variable:** si el controlador cambia con el tiempo, se generan nuevas direcciones de información.
- **Excitación externa:** una referencia r_k persistentemente excitante aporta información independiente.

CONSIDERACIONES

- La realimentación aporta un cierto grado de correlación entre entrada y salida por lo que se deben contemplar modelos de ruido coloreado para evitar estimaciones sesgadas.
- Recuperar la identificabilidad no implica necesariamente una convergencia rápida: la estimación puede acercarse rápidamente al subespacio identificable y evolucionar lentamente en las direcciones restantes.

Acá vimos 'identificacion_LC.m'.

IV: variables instrumentales. ¿Armax? ¿Diferencia?