Identificación y Control Adaptativo
Modelos y Predictores

Pablo Gonzalez

FIUBA

2026

1. Planteo del problema
2. Resolución numérica
3. Algoritmos de Estimación
   - Aproximación heurística
   - Algoritmo de proyección
   - Aproximación estocástica
   - Método del gradiente
   - Variables Instrumentales
4. Modelos y Predictores
   - Modelo ARMAX
   - Modelo Box-Jenkin (BJ)
   - Modelo OE
   - Resumen



Criterios de estimación

Según el criterio de estimación (qué magnitud se busca minimizar) se distinguen:

- **Mínimos cuadrados (LS)**: minimiza la suma del error cuadrático (visto como error de ajuste)
- **Predicción de error (PEM)**: minimiza el error de predicción; es el criterio más general en identificación de sistemas. Volvemos sobre este criterio al final de la presentación.
- **Máxima verosimilitud (ML)**: maximiza la probabilidad de observar los datos dados los parámetros; en ruido gaussiano se reduce a LS.

- Se busca elegir los parámetros θ que hacen más probable la observación de los datos $L(\theta) = p(Y|\theta)$

$$\hat{\theta}_{ML} = \arg\max_{\theta} \log L(\theta)$$

- Equivalencia con LS: si los residuos son independientes, gaussianos, de media nula y varianza constante σ^2:

$$e_k = y_k - \hat{y}_k(\theta) \sim \mathcal{N}(0, \sigma^2)$$

Por independencia, la verosimilitud de los datos es:

$$L(\theta) = \prod_{k=1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{e_k^2}{2\sigma^2}\right]$$

Maximizar la verosimilitud equivale a maximizar su logaritmo:

$$\hat{\theta}_{ML} = \arg\max_{\theta} \log L(\theta) = \arg\min_{\theta} \sum_{k=1}^{N} e_k^2 \quad \Longrightarrow \quad \hat{\theta}_{ML} = \hat{\theta}_{LS}$$

- Bajo otras hipótesis probabilísticas, ML puede conducir a criterios de estimación diferentes de LS.

1. Planteo del problema
2. Resolución numérica
3. Algoritmos de Estimación
   - Aproximación heurística
   - Algoritmo de proyección
   - Aproximación estocástica
   - Método del gradiente
   - Variables Instrumentales
4. Modelos y Predictores
   - Modelo ARMAX
   - Modelo Box-Jenkin (BJ)
   - Modelo OE
   - Resumen

Métodos de optimización aplicables a los criterios vistos:

- **Gradiente descendente**: actualización iterativa según el gradiente del error.

$$\Delta\theta = -\mu \nabla_\theta J(\theta)$$

- **Método de Newton / Gauss-Newton**: usan derivadas segundas (o aproximadas) para acelerar convergencia.

$$\Delta\theta = (J_\theta^\top J_\theta)^{-1} J_\theta^\top e$$

  donde J_θ es el jacobiano de los errores

- **Levenberg–Marquardt**: mezcla entre gradiente y Gauss-Newton (usado en redes neuronales y PEM).

$$\Delta\theta = (J_\theta^\top J_\theta + \lambda \mathbb{I})^{-1} J_\theta^\top e$$

- **Método recursivo (RLS)**: versión en línea del LS, actualiza con cada nueva muestra.

1. Planteo del problema
2. Resolución numérica
3. Algoritmos de Estimación
   - Aproximación heurística
   - Algoritmo de proyección
   - Aproximación estocástica
   - Método del gradiente
   - Variables Instrumentales
4. Modelos y Predictores
   - Modelo ARMAX
   - Modelo Box-Jenkin (BJ)
   - Modelo OE
   - Resumen

Dada una planta de primer orden, con el parámetro a conocido

$$
\begin{aligned}
y_{k+1} &= a\,y_k + b\,u_k \\
\hat{y}_{k+1} &= a\,y_k + \hat{b}\,u_k \\
e_{k+1} &= y_{k+1} - \hat{y}_{k+1} = (b - \hat{b})u_k
\end{aligned}
$$

Propongo u_k escalón

$$
\begin{aligned}
e_{k+1} &= b - \hat{b} \\
b &= \hat{b} + e_{k+1}
\end{aligned}
$$

Donde reinterpretamos esta ecuación en forma recursiva pensando que b es la estimación en $k+1$

$$\hat{b}_{k+1} = \hat{b} + \gamma\, e_{k+1}$$

Si el escalón es negativo, el algoritmo anterior no funciona. Se ajusta la ganancia con el signo de u_k

$$\hat{b}_{k+1} = \hat{b} + \gamma \frac{u_k}{|u_k|} e_{k+1}$$

A fin de vectorizar, una mejor versión es el algoritmo de *Kaczmarz*

$$\hat{b}_{k+1} = \hat{b} + \gamma \frac{u_k}{u_k^2} e_{k+1}$$

Se puede regularizar para que el denominador no se anule

$$\hat{b}_{k+1} = \hat{b} + \gamma \frac{u_k}{1 + u_k^2} e_{k+1}$$

Definimos

- Error *a priori*: $e_{k+1} = y_{k+1} - \hat{y}_{k+1}$, donde $\hat{y}_{k+1} = \varphi_k^\top \theta_k$
- Error *a posteriori*: $\bar{e}_{k+1} = y_{k+1} - \bar{y}_{k+1}$, donde $\bar{y}_{k+1} = \varphi_k^\top \theta_{k+1}$

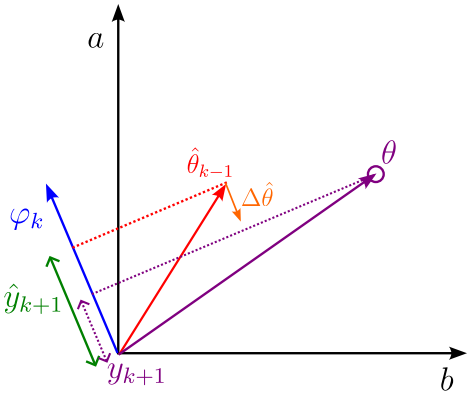
Entonces,

$$\begin{aligned}
\bar{y}_{k+1} &= a\, y_k + \hat{b}_{k+1} u_k \\
&= a\, y_k + \hat{b}_k u_k + \gamma \frac{u_k^2}{1+u_k^2}\, e_{k+1} \\
&= \hat{y}_{k+1} + \gamma \frac{u_k^2}{1+u_k^2}\, e_{k+1} \\
\bar{e}_{k+1} &= y_{k+1} - \hat{y}_{k+1} - \gamma \frac{u_k^2}{1+u_k^2}\, e_{k+1}
\end{aligned}$$

Finalmente, el error *a posteriori* es menor que el error *a priori*

$$\bar{e}_{k+1} = \left(1 - \gamma \frac{u_k^2}{1+u_k^2}\right) e_{k+1}$$

- La predicción $\hat{y}_{k+1} = \varphi_k^\top \hat{\theta}_k$ expresa una proyección del vector de parámetros sobre las mediciones
- Se propone ajustar $\hat{\theta}$ según la dirección de φ_k y el error de proyección



Del planteo geométrico surge,

$$\hat{\theta}_k = \hat{\theta}_{k-1} + \lambda\, \varphi_k$$
$$\lambda = \frac{\gamma}{\|\varphi_k\|^2} \left(y_k - \varphi_k^\top \hat{\theta}_{k-1} \right)$$

Regularizando para $\alpha > 0$,

$$\hat{\theta}_k = \hat{\theta}_{k-1} + \frac{\gamma\, \varphi_k}{\alpha + \varphi_k^\top \varphi_k} \left(y_k - \varphi_k^\top \hat{\theta}_{k-1} \right)$$

Comparar con RLS

Supongamos que θ_0 es el valor verdadero convencional de los parámetros. Definimos el incremento:

$$\tilde{\theta} = \hat{\theta} - \theta_0$$

Reemplazando en la ec. de actualización de los parámetros,

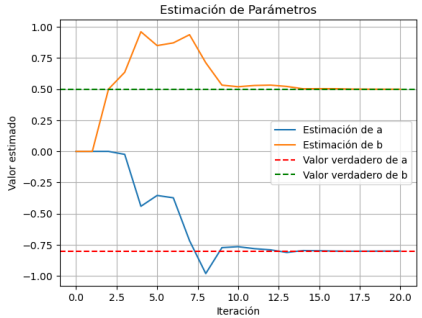
$$\tilde{\theta}_k = \tilde{\theta}_{k-1} + \frac{\gamma\, \varphi_k}{\alpha + \varphi_k^\top \varphi_k} \left(\varphi_k^\top \theta_0 - \varphi_k^\top \hat{\theta}_{k-1} \right) = \tilde{\theta}_{k-1} + \frac{\gamma\, \varphi_k \varphi_k^\top}{\alpha + \varphi_k^\top \varphi_k} \tilde{\theta}_{k-1}$$

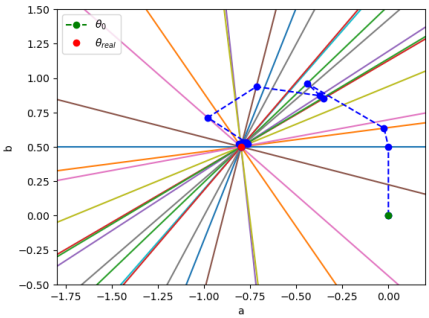
que describe la ecuación de actualización del estado con la matriz de transición

$$\Phi = \mathbb{I} - \frac{\gamma\, \varphi_k \varphi_k^\top}{\alpha + \varphi_k^\top \varphi_k} \qquad \text{con} \quad \lambda = \frac{\alpha + (1-\gamma)\, \varphi_k \varphi_k^\top}{\alpha + \varphi_k^\top \varphi_k}$$

Para convergencia se pide $|\lambda| < 1$, y por lo tanto $0 < \gamma < 2$

$$y_k = a\, y_{k-1} + b\, u_{k-1}$$





Ver notebook con el ejemplo

Comparando los algortimos vistos hasta aquí, se observa la misma forma en todos ellos:

- Mínimos cuadrados

$$\hat{\theta}_k = \hat{\theta}_{k-1} + P_k \varphi_k \left(y_k - \varphi_k^\top \hat{\theta}_{k-1} \right)$$

- Heurístico

$$\hat{\theta}_k = \hat{\theta}_{k-1} + \frac{\gamma}{1 + \varphi^\top \varphi} \varphi_k \left(y_k - \varphi_k^\top \hat{\theta}_{k-1} \right)$$

- Proyección

$$\hat{\theta}_k = \hat{\theta}_{k-1} + \frac{\gamma}{\alpha + \varphi^\top \varphi} \varphi_k \left(y_k - \varphi_k^\top \hat{\theta}_{k-1} \right)$$

Se propone la aproximación estocástica con la misma estructura

$$\hat{\theta}_k = \hat{\theta}_{k-1} + p_k \varphi_k \left(y_k - \varphi_k^\top \hat{\theta}_{k-1} \right)$$

donde p_k es una función decreciente en k

En los métodos anteriores se observa:

- LS minimiza $J_k = E_k^t E_k$ con la *pseudoinversa* de la matriz de observación
- RLS aplica pequeñas correcciones en cada iteración, pero siempre resolviendo linealmente

Tomando estas ideas se puede hacer un planteo más general sobre la actualización de la estimación

$$\hat{\theta}_{k+1} = \hat{\theta}_k - F \frac{\partial J_{k+1}}{\partial \hat{\theta}_k}$$

El gradiente se obtiene derivando (numéricamente) el funcional

$$\frac{\partial J_{k+1}}{\partial \hat{\theta}_k} = \frac{\partial e_{k+1}}{\partial \hat{\theta}_k} e_{k+1}$$

Para el caso lineal se reduce a los métodos vistos pues,

$$\frac{\partial J_{k+1}}{\partial \hat{\theta}_k} = -\varphi_k \, e_{k+1}$$

- Mínimos cuadrados puede producir estimaciones sesgadas cuando el regresor está correlacionado con la perturbación.
- Reemplazar el regresor en las ecuaciones de estimación por una señal instrumental z que esté correlacionada con φ, pero no con la perturbación.

$$y_k = \varphi_k^\top \theta + e_k$$
$$\mathbb{E}[z_k y_k] = \mathbb{E}[z_k \varphi_k^\top]\theta + \cancel{\mathbb{E}[z_k e_k]}$$

Reemplazando la esperanza por promedios muestrales se tiene

$$\hat{\theta}_{\text{IV}} = \left(\sum z_k \varphi_k^\top\right)^{-1} \sum z_k y_k$$

En forma matricial resulta

$$\hat{\theta}_{IV} = (Z^\top \Phi)^{-1} Z^\top Y$$

Un instrumento válido debe satisfacer:

$$\underbrace{\mathbb{E}[z_k e_k] = 0}_{\text{Exogeneidad}}, \qquad \underbrace{\operatorname{rango} \mathbb{E}[z_k \varphi_k^\top] = n_\theta}_{\text{Relevancia}}$$

¿Cómo construir instrumentos adecuados? Consideremos un sistema representado por un modelo ARX e identificado en lazo cerrado. Debido a la realimentación, los regresores pueden estar correlacionados con el error de predicción.

- **A partir de la referencia:** utilizar muestras pasadas de $r(t)$ como instrumentos. Si la referencia es independiente de las perturbaciones, resulta ortogonal al error; su relevancia depende de la excitación y de la dinámica del lazo.
- **A partir de un modelo auxiliar:** estimar previamente un modelo por LS y simular su respuesta ante la referencia. Construir los instrumentos con las señales simuladas y_{sim} y u_{sim}, que dependen de la referencia y no de las perturbaciones de la medición.

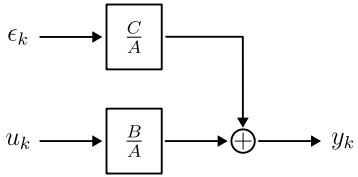
Ver script de matlab con el ejemplo

1. Planteo del problema
2. Resolución numérica
3. Algoritmos de Estimación
   - Aproximación heurística
   - Algoritmo de proyección
   - Aproximación estocástica
   - Método del gradiente
   - Variables Instrumentales
4. Modelos y Predictores
   - Modelo ARMAX
   - Modelo Box-Jenkin (BJ)
   - Modelo OE
   - Resumen

- **Objetivo**: Modelar la dinámica de la planta y construir predictores para estimar parámetros y/o residuos.
- **Flujo de trabajo**
  - Se parte de la planta
  - Se plantea un modelo (ARX, ARMAX, BJ, OE, etc.)
  - En función del modelo se define el predictor
  - Se plantea el estimador (RLS, RLSE, PEM, etc.)
  - Se obtiene el residuo
- **Residuo**: es la diferencia entre lo que dice el modelo y lo que dice la planta

$$e_k = y_k - \hat{y}_k$$

Es deseable que sea RB (ruido blanco); que no contenga información útil para la identificación. Se puede sofisticar el modelo para usar la información remanente.



$$y_k = \frac{B}{A}\,u_k + \frac{C}{A}\,\epsilon_k$$
$$A\,y_k = B\,u_k + C\,\epsilon_k$$

- El polinomio A es *mónico*
- El polinomio C modela el ruido coloreado
- Notar la dependencia de y_k con valores anteriores de la perturbación ϵ_{k-1}, etc.
- Si se propone el predictor

$$\hat{y}_k = (1 - A)y_k + Bu_k$$

el vector de parámetros obtenido por RLS resulta sesgado, ya que φ_k está correlacionado con ϵ_k

La ecuación de la planta perturbada con ϵ_k RB es:

$$y_k = a_1\, y_{k-1} + \ldots + b_1\, u_{k-1} + \ldots + \epsilon_k + c_1\, \epsilon_{k-1} + \ldots$$

Una buena estimación es aquella cuyo residuo es RB. Se plantea el predictor:

$$\hat{y}_k = \hat{a}_1\, y_{k-1} + \ldots + \hat{b}_1\, u_{k-1} + \ldots + \hat{c}_1\, \epsilon_{k-1} + \ldots$$

que consigue descorrelacionar el regresor φ_k y la perturbación, recuperando las características deseadas en el residuo cuando se usa RLS

Dado la ecuación del predictor

$$\hat{y}_k = \hat{a}_1\, y_{k-1} + \ldots + \hat{b}_1\, u_{k-1} + \ldots + \hat{c}_1\, \epsilon_{k-1} + \ldots$$

En el estimador por mínimos cuadrados se reinterpreta el vector regresor y el de parámetros

$$\varphi_k^\top = \begin{bmatrix} y_{k-1} & \ldots & u_{k-1} & \ldots & \epsilon_{k-1} & \ldots \end{bmatrix}$$
$$\theta_k^\top = \begin{bmatrix} \hat{a}_1 & \ldots & \hat{b}_1 & \ldots & \hat{c}_1 & \ldots \end{bmatrix}$$

Pero: ¿cómo se obtiene ϵ_k, si no se tiene acceso a esta señal?

Para entender cómo realizar la estimación considerar:

- Convergencia: $e_k \to \epsilon_k$
- Bajo esta hipótesis, se estima ϵ_k con el error de predicción. La forma del predictor resulta:

$$\hat{y}_k = \hat{a}_1\, y_{k-1} + \ldots + \hat{b}_1\, u_{k-1} + \ldots + \hat{c}_1\, (y_{k-1} - \hat{y}_{k-1}) + \ldots$$

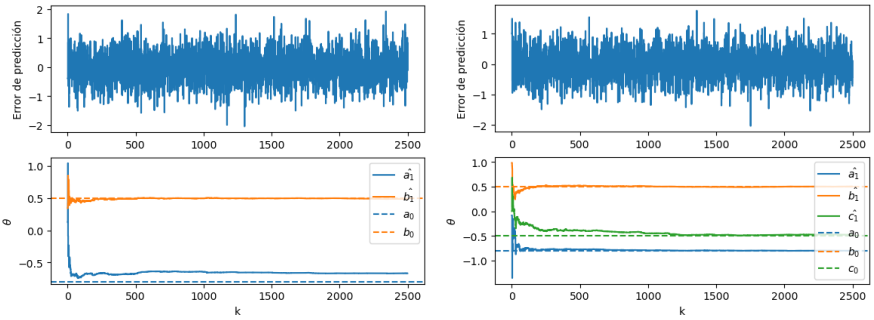
Para realizar la estimación, basta reinterpretar los vectores de RLS

$$\varphi_k^\top = \begin{bmatrix} y_{k-1} & \ldots & u_{k-1} & \ldots & (y_{k-1} - \hat{y}_{k-1}) & \ldots \end{bmatrix}$$
$$\theta_k^\top = \begin{bmatrix} \hat{a}_1 & \ldots & \hat{b}_1 & \ldots & \hat{c}_1 & \ldots \end{bmatrix}$$

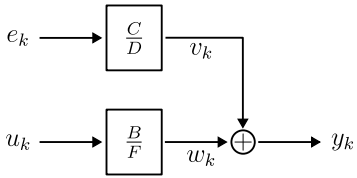
Particularidades:

- Los parámetros del ruido difícilmente convergen. Además no se usan en el control.
- Los parámetros de la planta convergen más lentamente que en modelos ARX

$$y_k = a\, y_{k-1} + b\, u_k + e_k + c\, e_{k-1}$$



Ver notebook con el ejemplo



$$y_k = \frac{B}{F}u_k + \frac{C}{D}e_k$$

- Los polinomios F, C y D son *mónicos*.
- Se puede llevar a la forma del predictor descorrelacionando primero e_k y luego expresando y_k en función de las muestras pasadas.

$$\frac{D}{C}y_k = \frac{D\,B}{C\,F}u_k + e_k$$
$$y_k = \left(1 - \frac{D}{C}\right)y_k + \frac{D\,B}{C\,F}u_k + e_k$$

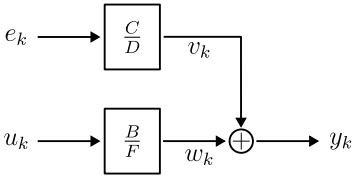
Operando sobre la ecuación del modelo se llega al predictor:

$$
\begin{aligned}
y_k &= \left(1 - \frac{D}{C}\right) y_k + \frac{D\,B}{C\,F} u_k + e_k \\
\hat{y}_k &= \left(1 - \frac{D}{C}\right) y_k + \frac{D\,B}{C\,F} u_k \\
C\,F\,\hat{y}_k &= (C\,F - D\,F)\, y_k + D\,B\,u_k \\
\hat{y}_k &= (1 - C\,F)\,\hat{y}_k + (C\,F)\, y_k - (D\,F)\, y_k + D\,B\,u_k
\end{aligned}
$$

Luego se reinterpreta el regresor para RLS según:

$$
\varphi_k^\top = \begin{bmatrix} \hat{y}_{k-1} & \cdots & y_{k-1} & \cdots & y_{k-1} & \cdots & u_{k-1} & \cdots \end{bmatrix}
$$

Pero RLS dará los coeficientes de CD, DF y DB, que no sirven para el control.



El estimador se construye restando e_k

$$y_k = w_k + v_k$$
$$\hat{y}_k = w_k + v_k - e_k$$

Además $Bu = Fw$, y por lo tanto:

$$w_k = b_1 u_{k-1} + b_2 u_{k-2} + \ldots - f_1 w_{k-1} - f_2 w_{k-2} - \ldots$$

Por otro lado $Ce = Dv$ resultando:

$$v_k = e_k + c_1 e_{k-1} + \ldots - d_1 v_{k-1} - d_2 v_{k-2} - \ldots$$

Reemplazando w_k y v_k en la expresión del predictor se tiene:

$$\hat{y}_k = b_1 u_{k-1} + b_2 u_{k-2} + \ldots - f_1 w_{k-1} - f_2 w_{k-2} - \ldots + \cancel{e_k} + c_1 e_{k-1} + \ldots - d_1 v_{k-1} - d_2 v_{k-2} - \ldots - \cancel{e_k}$$

Dada la ecuación del predictor

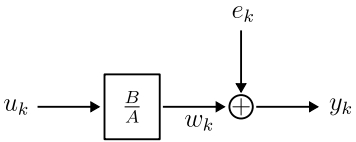
$$\hat{y}_k = b_1 u_{k-1} + \ldots - f_1 w_{k-1} - \ldots + c_1 e_{k-1} + \ldots - d_1 v_{k-1} - \ldots = \varphi_k^\top \theta_k$$

Se reinterpretan los vectores de RLS según:

$$\varphi_k^\top = \begin{bmatrix} u_{k-1} & \ldots & -w_{k-1} & \ldots & e_{k-1} & \ldots & -v_{k-1} & \ldots \end{bmatrix}$$
$$\theta_k^\top = \begin{bmatrix} b_1 & \ldots & f_1 & \ldots & c_1 & \ldots & d_1 & \ldots \end{bmatrix}$$

Con las siguientes variables auxiliares construidas a partir de mediciones y estimaciones

$$w_k = b_1 u_{k-1} + \ldots - f_1 w_{k-1} - \ldots$$
$$v_k = y_k - w_k$$
$$e_k = y_k - \varphi_k^\top \theta_k$$



$$y_k = \frac{B}{A} u_k + e_k$$

- Hasta aquí se modelaron perturbaciones dadas por error de ecuación.
- OE busca modelar una perturbación RB que afecta a la medición

Dada la ecuación de la planta, el predictor difiere solo en RB,

$$y_k = \frac{B}{A} u_k + e_k$$
$$\hat{y}_k = \frac{\hat{B}}{\hat{A}} u_k$$

Expresado en la forma del predictor resulta:

$$\hat{A}\, \hat{y}_k = \hat{B}\, u_k$$
$$\hat{y}_k = \hat{a}_1 \hat{y}_{k-1} + \ldots + \hat{b}_1 u_{k-1} + \ldots$$

Lo que permite reinterpretar los vectores de RLS, notando que en realidad el problema es **no lineal**

$$\varphi_k^\top = \begin{bmatrix} \hat{y}_{k-1} & \ldots & u_{k-1} \end{bmatrix}$$
$$\theta_k^\top = \begin{bmatrix} \hat{a}_1 & \ldots & \hat{b}_1 & \ldots \end{bmatrix}$$

Consideraciones:

- En el modelo OE, el funcional $J = \sum e_k^2$ es no lineal en θ , por lo que RLS es no consistente
- Se puede linealizar con una aproximación de 1° orden

$$e(k, \theta + \Delta\theta) \sim e(k, \theta) - \frac{\partial \hat{y}}{\partial \theta}^\top \Delta\theta$$

- Se define el vector de sensibilidades: $\varphi_k^\top = \frac{\partial \hat{y}}{\partial \theta}$

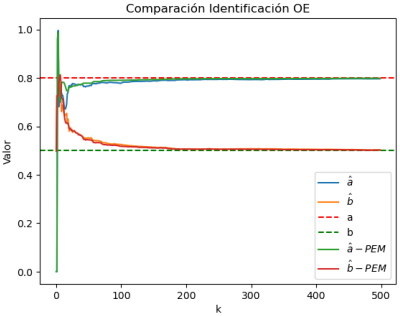
Luego, el funcional se expresa en términos del vector de sensibilidades y resulta un problema lineal en $\Delta\theta$

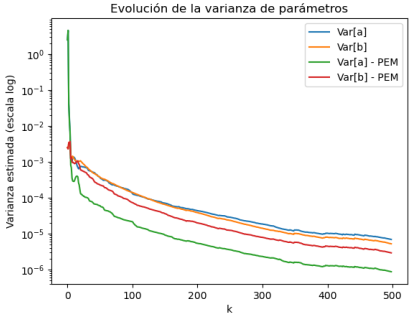
$$J(\theta + \Delta\theta) \sim \sum [e(k, \theta) - \varphi_k^\top \Delta\theta]^2$$

$$\frac{\partial \hat{y}_k}{\partial \hat{a}_i} = s_{a_i}(k) = \hat{y}_{k-i} + a_i s_{a_i}(k - i)$$

$$\frac{\partial \hat{y}_k}{\partial \hat{b}_i} = s_{b_i}(k) = u_{k-i} + b_i s_{b_i}(k - i)$$

$$y_k = \frac{B}{A} u_k + e_k$$





Ver notebook con el ejemplo



Resumen de modelos

Modelo	Qué estima	Residuo	Uso típico
ARX	Planta	No corrige perturbación	Control clásico, rápido
ARMAX	Planta + ruido	Residuo decorrelacionado	Mejora predicción
BJ	Planta + ruido	Residuo decorrelacionado, estructura más flexible	Identificación precisa
OE	Planta con perturbación en medición	Modela perturbación en la salida	Modelado cuando el ruido no afecta la dinámica