

IDENTIFICACIÓN Y CONTROL ADAPTATIVO

IDENTIFICACIÓN PARAMÉTRICA

Pablo Gonzalez

FIUBA

2026




- 1 INTRODUCCIÓN
- 2 MODELO DE REGRESIÓN
- 3 IDENTIFICACIÓN POR MÍNIMOS CUADRADOS
- 4 MÍNIMOS CUADRADOS RECURSIVOS
- 5 CONDICIONES EXPERIMENTALES
- 6 ESTRUCTURA DEL MODELO
- 7 VALIDACIÓN DEL MODELO



¿QUÉ SIGNIFICA IDENTIFICAR UN SISTEMA?

- Tenemos datos medidos de entrada y salida.
- Queremos construir un modelo que reproduzca la dinámica observada.
- Los parámetros del modelo son desconocidos y deben estimarse.



IDEA CENTRAL

No partimos necesariamente de las ecuaciones físicas del sistema:

- proponemos una estructura del modelo
- y aprendemos sus parámetros a partir de datos.



- 1 INTRODUCCIÓN
- 2 MODELO DE REGRESIÓN**
- 3 IDENTIFICACIÓN POR MÍNIMOS CUADRADOS
- 4 MÍNIMOS CUADRADOS RECURSIVOS
- 5 CONDICIONES EXPERIMENTALES
- 6 ESTRUCTURA DEL MODELO
- 7 VALIDACIÓN DEL MODELO



Supongamos un modelo lineal en los parámetros. Se puede escribir:

$$y_k = \varphi_k^\top \theta + e_k$$

donde

- y_k : salida medida,
- φ_k : vector de regresores conocidos,
- θ : parámetros desconocidos,
- e_k : error de modelado + ruido.

Para muchos modelos dinámicos, los regresores contienen muestras pasadas:

$$\varphi_k = [y_{k-1} \quad \cdots \quad y_{k-n} \quad u_{k-1} \quad \cdots \quad u_{k-m}]^\top$$



Se tiene un modelo lineal de segundo orden de tipo ARX:

$$A(q)y_k = B(q)u_k + e_k$$

Se lleva a la forma de predicción,

$$y_k = a_1 y_{k-1} + a_2 y_{k-2} + b_1 u_{k-1} + b_2 u_{k-2} + e_k$$

y factorizando los parámetros, queda en la forma de regresión

$$y_k = \underbrace{\begin{bmatrix} y_{k-1} & y_{k-2} & u_{k-1} & u_{k-2} \end{bmatrix}}_{\varphi_k^\top} \underbrace{\begin{bmatrix} a_1 \\ a_2 \\ b_1 \\ b_2 \end{bmatrix}}_{\theta} + e_k$$



EJEMPLO: MODELO NARX

Consideremos un péndulo simple:

$$J\ddot{y}(t) + b\dot{y}(t) + mgl \sin(y(t)) = \tau(t)$$

Se puede proponer un modelo discreto con la siguiente estructura:

$$y_k = \theta_1 y_{k-1} + \theta_2 y_{k-2} + \theta_3 \sin(y_{k-1}) + \theta_4 u_{k-1} + e_k$$

y llevarlo a la forma de regresión

$$y_k = \underbrace{\begin{bmatrix} y_{k-1} & y_{k-2} & \sin(y_{k-1}) & u_{k-1} \end{bmatrix}}_{\varphi_k^\top} \underbrace{\begin{bmatrix} \theta_1 \\ \theta_2 \\ \theta_3 \\ \theta_4 \end{bmatrix}}_{\theta} + e_k$$

El modelo puede ser **no lineal en las señales** y aún llevarlo a la forma de regresión



Con k observaciones, vectorizamos las ecuaciones:

$$Y_k = \Phi_k \theta + E_k$$

Para un modelo ARX de grado n , las matrices resultan

$$Y_k = \begin{bmatrix} y_k \\ \vdots \\ y_1 \end{bmatrix} \quad \Phi_k = \begin{bmatrix} y_{k-1} & \dots & y_{k-n} & u_{k-1} & \dots & u_{k-m} \\ \vdots & & \vdots & \vdots & & \vdots \\ y_0 & \dots & y_{1-n} & u_0 & \dots & u_{1-m} \end{bmatrix} \quad \theta = \begin{bmatrix} a_1 \\ \vdots \\ a_n \\ b_1 \\ \vdots \\ b_m \end{bmatrix} \quad E_k = \begin{bmatrix} e_k \\ \vdots \\ e_1 \end{bmatrix}$$



- 1 INTRODUCCIÓN
- 2 MODELO DE REGRESIÓN
- 3 IDENTIFICACIÓN POR MÍNIMOS CUADRADOS**
- 4 MÍNIMOS CUADRADOS RECURSIVOS
- 5 CONDICIONES EXPERIMENTALES
- 6 ESTRUCTURA DEL MODELO
- 7 VALIDACIÓN DEL MODELO



Sea la estimación $\hat{\theta}$, hasta el instante k se tendrá un error dado por el vector

$$E_k = Y_k - \Phi_k \hat{\theta}$$

El acumulado en las k mediciones del error cuadrático de la estimación resulta

$$J_k(\hat{\theta}) = E_k^\top E_k = (Y_k - \Phi_k \hat{\theta})^\top (Y_k - \Phi_k \hat{\theta}) = Y_k^\top Y_k + \hat{\theta}^\top \Phi_k^\top \Phi_k \hat{\theta} - 2 \hat{\theta}^\top \Phi_k^\top Y_k$$


En el mínimo de la función de costo se tiene que el gradiente se anula

$$\nabla_{\theta} J|_{\hat{\theta}} = 2 \Phi_k^\top \Phi_k \hat{\theta} - 2 \Phi_k^\top Y_k = 0$$

Despejando $\hat{\theta}_k$ se llega a la solución analítica del problema de estimación por LS

$$\hat{\theta}_k = \left(\Phi_k^\top \Phi_k \right)^{-1} \Phi_k^\top Y_k$$

$\Phi_k^\top \Phi_k$ es invertible cuando la información en los datos permite distinguir los distintos parámetros



- Las columnas de Φ generan un subespacio
- θ expresa las coordenadas de la estimación en ese espacio.
- $\hat{Y}$ está en el span de Φ
- E resulta ortogonal a $\hat{Y}$ cuando es mínimo

$$\varphi^\top E = 0$$

Identificar es encontrar la combinación de regresores que mejor explica las observaciones.



Supongamos que:

- θ son los parámetros *verdaderos*, y la estimación $\hat{\theta}$ es una variable aleatoria
- E es ruido blanco con varianza σ^2 e independiente de Φ

La esperanza de la estimación resulta

$$\begin{aligned} Y &= \Phi \theta + E \\ (\Phi^\top \Phi)^{-1} \Phi^\top Y &= (\Phi^\top \Phi)^{-1} \Phi^\top \Phi \theta + (\Phi^\top \Phi)^{-1} \Phi^\top E \\ \hat{\theta} &= \theta + (\Phi^\top \Phi)^{-1} \Phi^\top E \\ \mathbb{E} [\hat{\theta}] &= \theta + \cancel{\mathbb{E} \left[(\Phi^\top \Phi)^{-1} \Phi^\top E \right]} \end{aligned}$$

Bajo estas condiciones el estimador por LS para un modelo ARX es **insesgado**: $\mathbb{E} [\hat{\theta}] = \theta$



$$\Phi_k^T \Phi_k = \begin{bmatrix} y_{k-1} & \dots & y_0 \\ \vdots & & \vdots \\ y_{k-n} & \dots & y_{1-n} \\ u_{k-1} & \dots & u_0 \\ \vdots & & \vdots \\ u_{k-m} & \dots & u_{1-m} \end{bmatrix} \begin{bmatrix} y_{k-1} & \dots & y_{k-n} & u_{k-1} & \dots & u_{k-m} \\ \vdots & & \vdots & \vdots & & \vdots \\ y_0 & \dots & y_{1-n} & u_0 & \dots & u_{1-m} \end{bmatrix}$$

$$\Phi_k^T \Phi_k = \begin{bmatrix} r_y(0) & \dots & r_y(n-1) & r_{yu}(0) & \dots & r_{yu}(m-1) \\ \vdots & & \vdots & \vdots & & \vdots \\ r_y(n-1) & \dots & r_y(0) & r_{yu}(n-1) & \dots & r_{yu}(n-m) \\ r_{yu}(0) & \dots & r_{yu}(n-1) & r_u(0) & \dots & r_u(m-1) \\ \vdots & & \vdots & \vdots & & \vdots \\ r_{yu}(m-1) & \dots & r_{yu}(n-m) & r_u(m-1) & \dots & r_u(0) \end{bmatrix}$$

La **matriz de covarianza** ($\Phi^T \Phi$) representa la *cantidad de información* contenida en los datos



Para el modelo ARX sobre el que venimos trabajando

$$A(q)y_k = B(q)u_k + e_k$$

con $\deg A = n$, $\deg B = m$ y retardo $d = n - m$, el regresor resulta:

$$\varphi_k^\top = [y_{k-1} \quad \cdots \quad y_{k-n} \quad u_{k-d} \quad \cdots \quad u_{k-d-m+1}].$$

Por lo tanto,

$$\Phi^\top \Phi = \begin{bmatrix} R_{yy} & R_{yu} \\ R_{uy} & R_{uu} \end{bmatrix}$$

Donde los bloques diagonales contienen autocorrelaciones, mientras que los bloques cruzados incorporan el **retardo relativo** d :

$$R_{yy} \sim r_y(\ell) \quad R_{uu} \sim r_u(\ell) \quad R_{yu} \sim r_{yu}(d + \ell)$$



Sabemos que

$$\hat{\theta} = \theta + \left(\Phi^T \Phi \right)^{-1} \Phi^T E$$

Por lo tanto la covarianza del estimador resulta

$$\begin{aligned} \text{cov}(\hat{\theta}) &= \mathbb{E} \left[(\hat{\theta} - \theta) (\hat{\theta} - \theta)^T \right] \\ &= \mathbb{E} \left\{ \left(\Phi^T \Phi \right)^{-1} \Phi^T E E^T \Phi \left(\Phi^T \Phi \right)^{-1} \right\} \\ &= \sigma^2 \left(\Phi^T \Phi \right)^{-1} \end{aligned}$$

La **precisión del estimador** (medida como la inversa de la varianza) se ve afectada por:

- **Nivel de Ruido** (σ^2). A mayor ruido en las mediciones, mayor será la dispersión de los parámetros estimados
- **Matriz de Información** ($\Phi^T \Phi$). A medida que la entrada es más excitante y $N \rightarrow \infty$, los valores propios de $\Phi^T \Phi$ crecen, haciendo que $(\Phi^T \Phi)^{-1}$ sea más pequeña.



- Un estimador $\hat{\theta}$ es consistente si converge en probabilidad o en media cuadrática al valor verdadero del parámetro (θ) a medida que el número de muestras N tiende a infinito ($N \rightarrow \infty$)

$$\text{MSE}(\hat{\theta}) = E\{||\hat{\theta} - \theta||^2\} = ||\Delta(\hat{\theta})||^2 + \text{trace}(\text{cov}(\hat{\theta}))$$

- Dado que el estimador es insesgado el término de sesgo se anula. Por lo tanto, el error depende únicamente de la varianza:

$$\text{MSE}(\hat{\theta}) = \text{trace}(\text{cov}(\hat{\theta}))$$

- Al sumar muestras con señales persistentemente excitadoras $(\Phi^T \Phi)^{-1} \rightarrow 0$ y por lo tanto $\text{cov}(\hat{\theta}) \rightarrow 0$ cuando $N \rightarrow \infty$
- Se cumple así $\text{MSE}(\hat{\theta}) \rightarrow 0$. Esto asegura la convergencia en media cuadrática (lo que implica convergencia en probabilidad), demostrando que **el estimador por LS para un modelo ARX es consistente**



- Sistema de primer orden $y_k = 0,5y_{k-1} + u_{k-1}$
 - Entrada impulso ✓
 - Entrada escalón ✓
- Sistema de segundo orden $y_k = 1,2y_{k-1} - 0,32y_{k-2} + u_{k-1}$
 - Entrada impulso: rango de $\Phi = 2$ ✗
 - Entrada escalón ✓


Ver ejemplo en Matlab



- 1 INTRODUCCIÓN
- 2 MODELO DE REGRESIÓN
- 3 IDENTIFICACIÓN POR MÍNIMOS CUADRADOS
- 4 MÍNIMOS CUADRADOS RECURSIVOS**
- 5 CONDICIONES EXPERIMENTALES
- 6 ESTRUCTURA DEL MODELO
- 7 VALIDACIÓN DEL MODELO



- En aplicaciones como el control adaptativo, los datos llegan secuencialmente.
- Recalcular la solución de mínimos cuadrados completa en cada instante es ineficiente.
- Los algoritmos recursivos evitan este recálculo.
- En cada paso, actualizan la estimación anterior con la nueva información.
- Por lo que permite ajustar modelos ante dinámicas cambiantes o desconocidas.





Definamos la matriz de incertidumbre P_k como la inversa de la matriz de covarianza

$$P_k^{-1} = \Phi_k^\top \Phi_k = [\varphi_k \quad \dots \quad \varphi_0] \begin{bmatrix} \varphi_k^\top \\ \vdots \\ \varphi_0^\top \end{bmatrix} = \sum_{i=0}^k \varphi_i \varphi_i^\top = P_{k-1}^{-1} + \varphi_k \varphi_k^\top$$

Luego el vector b_k

$$b_k = \Phi_k^\top Y_k = [\varphi_k \quad \dots \quad \varphi_0] \begin{bmatrix} y_k \\ \vdots \\ y_0 \end{bmatrix} = \sum_{i=0}^k \varphi_i y_i = b_{k-1} + \varphi_k y_k$$

Con estas definiciones el estimador por mínimos cuadrados resulta:

$$\hat{\theta}_k = \left(\Phi_k^\top \Phi_k \right)^{-1} \Phi_k^\top Y_k = P_k b_k$$



La inversa de P_k puede expresarse en función de su valor anterior más otra matriz que aporta la *novedad*.

$$P_k^{-1} = P_{k-1}^{-1} + \varphi_k \varphi_k^\top \Rightarrow P_k P_k^{-1} P_{k-1} = P_k P_{k-1}^{-1} P_{k-1} + P_k \varphi_k \varphi_k^\top P_{k-1} \Rightarrow P_{k-1} = P_k + P_k \varphi_k \varphi_k^\top P_{k-1}$$

Aun debemos dejar P_k en función de P_{k-1} y los datos nuevos. Si posmultiplicamos por φ_k :

$$P_{k-1} \varphi_k = P_k \varphi_k + P_k \varphi_k \varphi_k^\top P_{k-1} \varphi_k = P_k \varphi_k \left[1 + \varphi_k^\top P_{k-1} \varphi_k \right] \Rightarrow P_{k-1} \varphi_k \left[1 + \varphi_k^\top P_{k-1} \varphi_k \right]^{-1} = P_k \varphi_k$$

De las dos ecuaciones anteriores encontramos la expresión en recurrencia para P_k

$$P_k = P_{k-1} - \frac{P_{k-1} \varphi_k \varphi_k^\top P_{k-1}}{1 + \varphi_k^\top P_{k-1} \varphi_k}$$



- P_{k-1} representa la incertidumbre que tenemos antes de incorporar la nueva observación.
- φ_k : representa la nueva dirección de información que aporta la observación.
- $P_{k-1}\varphi_k$: proyecta esa nueva información sobre la geometría de nuestra incertidumbre. **Indica en qué dirección podemos reducir la incertidumbre.**
- $(P_{k-1}\varphi_k)(P_{k-1}\varphi_k)^\top$: concentra el recorte de incertidumbre en esa dirección.
- $\varphi_k^\top P_{k-1}\varphi_k$: mide cuánta incertidumbre tenemos asociada a esa nueva dirección.
- $1 + \varphi_k^\top P_{k-1}\varphi_k$: regula la magnitud del recorte. La reducción se adapta a la incertidumbre disponible en esa dirección.

Por ejemplo:

- Si $P_{k-1}\varphi_k \approx 0$: la nueva observación aporta poca información útil y $P_k \approx P_{k-1}$.
- Si $P_{k-1}\varphi_k$ es grande: la observación incide sobre una dirección donde todavía hay bastante incertidumbre y el recorte es mayor.

RLS actualiza la incertidumbre recortándola en las direcciones donde la nueva observación aporta información.



Reemplazando la fórmula de recurrencia de P_k y b_k en la expresión de la estimación de los parámetros:

$$\hat{\theta}_k = P_k b_k = \left[P_{k-1} - \frac{P_{k-1} \varphi_k \varphi_k^\top P_{k-1}}{1 + \varphi_k^\top P_{k-1}} \right] [b_{k-1} + \varphi_k y_k]$$

$$\hat{\theta}_k = \hat{\theta}_{k-1} - \frac{P_{k-1} \varphi_k \varphi_k^\top P_{k-1}}{1 + \varphi_k^\top P_{k-1}} [b_{k-1} + \varphi_k y_k] + P_{k-1} \varphi_k y_k$$

$$\hat{\theta}_k = \hat{\theta}_{k-1} - P_k \varphi_k \varphi_k^\top P_{k-1} [b_{k-1} + \varphi_k y_k] + P_{k-1} \varphi_k y_k$$

$$\hat{\theta}_k = \hat{\theta}_{k-1} - P_k \varphi_k \varphi_k^\top \hat{\theta}_{k-1} + \left[P_{k-1} - P_k \varphi_k \varphi_k^\top P_{k-1} \right] \varphi_k y_k$$

$$\hat{\theta}_k = \hat{\theta}_{k-1} - P_k \varphi_k \varphi_k^\top \hat{\theta}_{k-1} + P_k \varphi_k y_k$$

$$\boxed{\hat{\theta}_k = \hat{\theta}_{k-1} - P_k \varphi_k \left[\varphi_k^\top \hat{\theta}_{k-1} - y_k \right]}$$

La estimación se corrige en la dirección de la nueva información, escalada por el error de predicción.



Si definimos

$$K_{k-1} = \frac{P_{k-1} \varphi_k}{1 + \varphi_k^\top P_{k-1} \varphi_k}$$


Podemos expresar las ecuaciones de actualización de incertidumbre y parámetros como:

$$\begin{aligned} P_k &= P_{k-1} - K_{k-1} \varphi_k^\top P_{k-1} \\ \hat{\theta}_k &= \hat{\theta}_{k-1} + K_{k-1} [y_k - \hat{y}_k] \end{aligned}$$

- K_k : actúa como una **ganancia de Kalman**, determinando cuánto y en qué dirección corregir la estimación.
- $y_k - \hat{y}_k$: es la **innovación**, es decir, la información nueva que surge de comparar la medición con la predicción.
- P_k : actualiza la **incertidumbre de los parámetros**, reduciéndola según la información aportada por la nueva observación.





- En el estimador anterior, todas las muestras tienen el mismo peso. Si los parámetros del sistema varían con el tiempo, las muestras antiguas pueden dejar de ser representativas del sistema actual



- Se introduce un **factor de olvido** $0 < \lambda \leq 1$, que pondera las muestras según su antigüedad

$$1, \quad \lambda, \quad \lambda^2, \quad \lambda^3, \dots$$

- De este modo, las observaciones tienen una influencia que decrece exponencialmente con el tiempo.



El valor de λ establece un compromiso:

- $\lambda \approx 1$: mayor memoria y seguimiento más suave.
- $\lambda \searrow$: menor memoria y adaptación más rápida, pero mayor sensibilidad al ruido.



Se redefine la función de costo a minimizar

$$J_k(\hat{\theta}) = E_k^\top Q_k E_k$$

donde Q es una matriz diagonal que marca una progresión exponencial λ^k . Igualando a cero el gradiente:

$$\nabla_{\theta} J|_{\hat{\theta}} = 2\Phi_k^\top Q_k \Phi_k \hat{\theta} - 2\Phi_k^\top Q_k Y_k = 0$$

Se despeja $\hat{\theta}_k$,

$$\hat{\theta}_k = \left(\Phi_k^\top Q_k \Phi_k \right)^{-1} \Phi_k^\top Q_k Y_k$$

O en forma recursiva,

$$P_k = \frac{1}{\lambda} \left[P_{k-1} - \frac{P_{k-1} \varphi_k \varphi_k^\top P_{k-1}}{\lambda + \varphi_k^\top P_{k-1} \varphi_k} \right]$$

$$\hat{\theta}_k = \hat{\theta}_{k-1} - P_k \varphi_k [\hat{y}_k - y_k]$$



- 1 INTRODUCCIÓN
- 2 MODELO DE REGRESIÓN
- 3 IDENTIFICACIÓN POR MÍNIMOS CUADRADOS
- 4 MÍNIMOS CUADRADOS RECURSIVOS
- 5 CONDICIONES EXPERIMENTALES**
- 6 ESTRUCTURA DEL MODELO
- 7 VALIDACIÓN DEL MODELO



- Para que el estimador LS determine una solución única, se requiere $\Phi^T \Phi$ invertible. Es decir, que las señales regresoras **aporten información independiente**.
- Esta condición sobre los datos se formaliza mediante la **Excitación Persistente (PE)**.
- Una señal u_k es PE de orden n si la matriz de covarianza C_n es definida positiva

$$C_n \succ 0 \iff \|\Phi x\|^2 > 0 \quad \forall x \neq 0 \iff \text{rank}(\Phi) = n$$

- **Interpretación:** la entrada debe explorar suficientemente distintas direcciones del espacio de regresores.
- Para estimar un modelo con p parámetros, se requiere excitación persistente de orden suficiente para que las p direcciones puedan distinguirse.



Tipo de Señal	Orden Máximo de PE	Comentario
Pulso	0	No es PE de ningún orden.
Escalón	1	Solo puede identificar un parámetro (p.ej., la ganancia estática).
Senoide pura	2	Puede identificar hasta dos parámetros.
Suma de k sinusoides	$2k$	El orden aumenta con la riqueza espectral.
Secuencia PRBS	Muy alto	Buena elección para identificación, ya que su espectro es casi plano.
Ruido blanco	Infinito	Es excitante de cualquier orden.

[Ver ejemplo](#)



La velocidad con la que la varianza del estimador converge a cero depende del comportamiento asintótico de los regresores.

- Si los regresores son acotados (ej: entrada PRBS), la varianza decrece como $1/N$.
- Si los regresores decrecen muy rápido (ej: entrada pulso), la varianza puede no converger a cero.
- Si los regresores crecen con el tiempo, la varianza converge a cero más rápidamente.



Para que LS sea insesgado se requiere que el ruido sea incorrelacionado con los regresores:

$$\mathbb{E}\{\varphi_k e_k\} = 0.$$

En modelos con dinámica del ruido, como ARMAX, esta condición puede violarse porque las salidas pasadas pertenecen al vector de regresores

¿Cómo evitar el sesgo?

- **Mínimos Cuadrados Extendidos ELS:** incorpora estimaciones del ruido pasado al vector de regresores.
- **Variables Instrumentales (IV):** utiliza variables correlacionadas con los regresores, pero incorrelacionadas con el ruido.
- **Máxima Verosimilitud (ML):** estima los parámetros buscando maximizar la probabilidad de los datos observados bajo un modelo estadístico del ruido.



Cuando el sistema opera en lazo cerrado, entrada y salida dejan de ser independientes. Por ejemplo,

$$u_k = -K y_k$$

introduce una dependencia entre las señales que forman los regresores. Esto puede reducir el rango de Φ y provocar una pérdida de identificabilidad: $\text{rank}(\Phi) < n \implies \Phi^\top \Phi$ singular

¿Cómo recuperar la identificabilidad?

- **Regulador dinámico:** una estructura de orden suficiente puede evitar la dependencia lineal simple entre entrada y salida.
- **Ganancia variable:** si el controlador cambia con el tiempo, se generan nuevas direcciones de información.
- **Excitación externa:** una referencia $r(k)$ persistentemente excitante aporta información independiente.

Recuperar la identificabilidad no implica necesariamente una convergencia rápida: la estimación puede acercarse rápidamente al subespacio identificable y evolucionar lentamente en las direcciones restantes.



- 1 INTRODUCCIÓN
- 2 MODELO DE REGRESIÓN
- 3 IDENTIFICACIÓN POR MÍNIMOS CUADRADOS
- 4 MÍNIMOS CUADRADOS RECURSIVOS
- 5 CONDICIONES EXPERIMENTALES
- 6 ESTRUCTURA DEL MODELO**
- 7 VALIDACIÓN DEL MODELO



- La identificación no termina con la estimación de los parámetros: también debemos elegir una **estructura de modelo** adecuada.
- La complejidad del modelo debe ser suficiente para capturar la dinámica relevante, pero sin incorporar el ruido de los datos.
- **Subajuste:** modelo demasiado simple.
 - No captura toda la dinámica del sistema.
 - Presenta errores sistemáticos en los datos.
- **Sobreajuste:** modelo demasiado complejo.
 - Se adapta muy bien a los datos utilizados para identificarlo.
 - Puede terminar modelando ruido en lugar de dinámica.
 - Su capacidad predictiva puede deteriorarse con datos nuevos.

Complejidad insuficiente $\longleftrightarrow$ Complejidad excesiva



- Para una misma estructura pueden considerarse distintos órdenes de los polinomios.
- Los criterios de selección buscan un compromiso entre **calidad del ajuste** y **complejidad del modelo**.
- Se evalúa el criterio para distintos órdenes y se selecciona el que **lo minimiza**.
- El **test F** permite evaluar si agregar parámetros produce una mejora estadísticamente significativa.


Criterio	Idea Principal	Fórmula
Error de Predicción Final	Error de predicción esperado en datos nuevos	$\text{FPE} = \hat{\sigma}^2 \frac{N+p}{N-p}$
Criterio de Información de Akaike	Ajuste + penalización por complejidad	$\text{AIC} = \log(\hat{\sigma}^2) + \frac{2p}{N}$
Longitud Mínima de Descripción	Ajuste + penalización más fuerte por complejidad	$\text{MDL} = \log(\hat{\sigma}^2) + \frac{p \log(N)}{N}$



- 1 INTRODUCCIÓN
- 2 MODELO DE REGRESIÓN
- 3 IDENTIFICACIÓN POR MÍNIMOS CUADRADOS
- 4 MÍNIMOS CUADRADOS RECURSIVOS
- 5 CONDICIONES EXPERIMENTALES
- 6 ESTRUCTURA DEL MODELO
- 7 VALIDACIÓN DEL MODELO**



- Los datos experimentales se dividen en dos conjuntos:
 - **Identificación:** utilizados para estimar los parámetros del modelo.
 - **Validación:** no utilizados durante la estimación.
- Una vez identificado el modelo, el conjunto de validación permite evaluar su comportamiento sobre datos que no utilizó para ajustarse.



La validación debe utilizar información independiente de la estimación



- Los experimentos preliminares y los modelos no paramétricos permiten obtener una idea inicial de la ubicación de polos y ceros.
- Se verifica que la ubicación obtenida en el modelo paramétrico sea **coherente con la información previa**.
- También es importante analizar el **modelo del ruido**:
 - frecuencias predominantes en el ruido deberían reflejarse en polos resonantes del modelo.
- La representación de polos y ceros permite detectar posibles **problemas de complejidad del modelo**:
 - orden excesivamente elevado;
 - polos muy cercanos a ceros, que pueden sugerir una **reducción de orden**.



Una vez estimado el modelo, podemos evaluarlo utilizando datos que no participaron en la identificación.

PREDICCIÓN

Se utiliza información disponible hasta el instante k para predecir la salida:

$$y(k) \quad \text{vs.} \quad \hat{y}(k|k-1)$$

Permite evaluar la capacidad predictiva del modelo.

SIMULACIÓN

Se aplica al modelo la misma entrada que al sistema:

$$y(k) \quad \text{vs.} \quad \hat{y}_{\text{sim}}(k)$$

Permite evaluar la reproducción de la dinámica del sistema.

¿CUÁL UTILIZAR?

Depende del propósito del modelo y del uso que se hará de él.



- Una vez estimado el modelo, definimos el residuo:

$$\epsilon(k) = y(k) - \hat{y}(k|\hat{\theta}).$$

- Si el modelo capturó adecuadamente la dinámica del sistema, los residuos deberían comportarse como **ruido blanco**: no deberían contener información predecible.
- **Un buen modelo deja residuos sin información predecible**. Se verifican principalmente dos condiciones:

AUTOCORRELACIÓN

$$R_{\epsilon\epsilon}(\tau) \approx \begin{cases} \sigma_{\epsilon}^2, & \tau = 0 \\ 0, & \tau \neq 0 \end{cases}$$

No debería quedar estructura temporal en los residuos.

CORRELACIÓN CON LA ENTRADA

$$R_{ue}(\tau) \approx 0$$


La entrada no debe contener información sobre el ruido.



- En un conjunto finito de datos, el ruido blanco presenta correlaciones muestrales distintas de cero.
- Para residuos aproximadamente gaussianos e independientes, la autocorrelación normalizada cumple:

$$\frac{R_{\epsilon\epsilon}(i)}{R_{\epsilon\epsilon}(0)} \sim \mathcal{N}\left(0, \frac{1}{N}\right) \implies \left| \frac{R_{\epsilon\epsilon}(i)}{R_{\epsilon\epsilon}(0)} \right| < \frac{2,17}{\sqrt{N}} \quad (98,5 \%)$$

- Si las autocorrelaciones están dentro de la banda, no hay evidencia fuerte de correlación temporal.
- Si aparecen valores fuera de la banda, puede existir información dinámica que el modelo no está capturando.



La prueba no busca autocorrelación exactamente nula: busca que las correlaciones sean compatibles con las fluctuaciones esperables en una muestra finita.