

IDENTIFICACIÓN Y CONTROL ADAPTATIVO PERTURBACIONES

Pablo Gonzalez

FIUBA

2026




1 INTRODUCCIÓN

2 MODELO DE PERTURBACIONES

- Determinístico
- Estocástico




- Las perturbaciones son unas de las razones de la existencia de la teoría de control




- Limitan el ancho de banda y comportamiento de un sistema.
- Midiendo perturbaciones se pueden detectar malfuncionamiento de los sistemas,
- Dos formas básicas de modelar una perturbación
 - determinística o clásica
 - estadística.



- Reducción en la fuente
 - reducción de variaciones en una concentración utilizando un mezclador eficiente,
 - reducción de fricción usando buenos rodamientos,
 - cambiar de posición los sensores para evitar perturbaciones, etc
- Realimentación local



- Control en adelante (feedforward): $C_{ff} = -\frac{G_w}{G}$




- Predicción, cuando la perturbación no es medible para cancelar por FF



1 INTRODUCCIÓN

2 MODELO DE PERTURBACIONES

- Determinístico
- Estocástico



- Perturbaciones en la salida d_o
El error de medición puede ser estático (de calibración) o de alta frecuencia (mitigar por filtrado y considerar el retardo)
- Perturbaciones de carga d_i
Son generalmente lentas o de bajas frecuencias. Ej: carga mecánica de un motor, olas en un barco.
- Variación de Parámetros
Por variación del punto de trabajo o por derivas del sistema. Se estudia como un cambio en el modelo de la planta en cambio los dos primeros como una dinámica adicional al sistema original




1 INTRODUCCIÓN

2 MODELO DE PERTURBACIONES





- Determinístico
- Estocástico



- Pueden modelarse como la respuesta a condiciones iniciales o al impulso de un sistema G_w



- Son determinísticas porque si bien no se conoce el instante en que ocurre el impulso, luego se puede determinar completamente a partir de las mediciones.
- Se destacan los tipos de corta duración, carga constante, deriva y periódica





- Para mejorar la capacidad de modelar las perturbaciones determinísticas se extiende la idea a que puedan variar aleatoriamente en múltiples instantes de tiempo. La entrada es 0 salvo en algunos momentos.

Modelo en el espacio de estados

$$x_{k+1} = \Phi x_k + v_k$$

$$y_k = Cx_k$$

El estado se calcula con la matriz de observabilidad W_o

$$x_{k-n+1} = W_o^{-1} [y_{k-n+1} \quad \dots \quad y_k]^t$$

Con la matriz de transición se predice a m pasos

$$\hat{x}_{k+m|k} = \Phi^{m+n-1} W_o^{-1} [y_{k-n+1} \quad \dots \quad y_k]^t$$

Recursivamente

$$\hat{x}_{k|k} = \Phi \hat{x}_{k-1|k-1} + K [y_k - C\Phi \hat{x}_{k-1|k-1}]$$

$$\hat{x}_{k+m|k} = \Phi^m \hat{x}_{k|k}$$

buscando K que anulen los autovalores de $(I - KC)\Phi$

Modelo de entrada-salida

$$y_k = \frac{C(q)}{A(q)} w_k$$

w_k es 0 salvo en pocos puntos separados a más de $\deg(A) + m$
Si se define F y G tal que cumplan

$$z^{m-1}C = A(z)F(z) + G(z)$$


se puede demostrar que un predictor a m pasos es

$$C(q)\hat{y}_{k+m|k} = qG(q)y_k$$



EJEMPLO

Considerar que se produce un efecto de deriva por las perturbaciones. Entonces puede modelarse como impulsos que actúan en momentos desconocidos sobre una dinámica del tipo *doble integrador*
Ver [notebook con el ejemplo](#) y el desarrollo matemático del estimador recursivo







1 INTRODUCCIÓN

2 MODELO DE PERTURBACIONES

- Determinístico
- Estocástico



- **Variable aleatoria:** magnitud caracterizada estadísticamente.
- **Proceso estocástico:** familia de variables aleatorias $\{X_k\}$, definidas sobre un mismo espacio de probabilidad, e indexadas por un parámetro (usualmente el tiempo) $k \in \mathcal{Z}$.
 - **Muestra temporal:** para $k = k_0$, el valor X_{k_0} es una variable aleatoria, y por lo tanto está caracterizado por una función de densidad de probabilidad (fdp).
 - **Realización:** es una función determinista x_k obtenida al fijar un resultado del experimento aleatorio. Representa una instancia del proceso estocástico $X_k(\omega)$ para un ω dado.



- **Ejemplo:** proceso determinístico con valor inicial aleatorio



- **Función de distribución:** $F_{X_k}(x) = \mathbb{P}(X_k \leq x)$
- **Función de densidad de probabilidad (fdp):** $f_{X_k}(x) = \frac{d}{dx} F_{X_k}(x)$
- **Estadísticos:**
 - **Esperanza:**

$$\mathbb{E}[X_k] = \int_{-\infty}^{\infty} \xi f_{X_k}(\xi) d\xi = m_{X_k}$$

- **Varianza:**

$$\text{Var}(X_k) = \mathbb{E}[(X_k - m_{X_k})(X_k - m_{X_k})^\top] = \sigma_{X_k}^2$$

- **Covarianza:**

$$\text{Cov}(X_k, X_i) = \mathbb{E}[(X_k - m_{X_k})(X_i - m_{X_i})^\top] = r_{XX}(k, i)$$

- **Covarianza cruzada de dos procesos estocásticos:**

$$\text{Cov}(X_k, Y_i) = r_{XY}(k, i)$$

- **Correlación**

$$R(X_k, Y_i) = \mathbb{E}[X_k Y_i^\top]$$



- Un proceso es **estrictamente estacionario** si su función de densidad conjunta no varía frente a desplazamientos en el tiempo.
- Es **débilmente estacionario**, o estacionario en sentido amplio (ESA), si sus primeros dos momentos (media y covarianza) no varían con el tiempo.
- En un proceso ESA se tiene:
 - **Valor medio** constante: $m_X = \text{cte}$
 - **Autocorrelación**: $R_X(k) = R_X(i+k, i)$ depende solo de la diferencia k
 - **Autocovarianza**: $r_X(k) = r_{XX}(i+k, i)$
 - **Covarianza cruzada de dos procesos conjuntamente estacionarios**: $r_{XY}(k) = r_{XY}(i+k, i)$
 - **Densidad espectral cruzada**:

$$\phi_{XY}(\omega) = \sum_{k=-\infty}^{\infty} r_{XY}(k) e^{-jk\omega}$$
$$r_{XY}(k) = \frac{1}{2\pi} \int_{-\pi}^{\pi} \phi_{XY}(\omega) e^{jk\omega} d\omega$$

- **Potencia de la señal**: en la banda $[\omega_1, \omega_2]$ es $2 \int_{\omega_1}^{\omega_2} \phi(\omega) d\omega$



- **Procesos independientes.** Se dice que un conjunto de variables aleatorias $\{X_k\}$ es independiente si para todo $k_1, \dots, k_n$:

$$\mathbb{P}[X_{k_1} \leq x_1, X_{k_2} \leq x_2, \dots, X_{k_n} \leq x_n] = \prod_{i=1}^n \mathbb{P}[X_{k_i} \leq x_i]$$

La independencia también se puede expresar a través de funciones de densidad conjunta o funciones de distribución. Dos procesos X e Y son independientes si:

$$\begin{aligned} \mathbb{P}[X_{k_1} \leq x_1, \dots, X_{k_n} \leq x_n, Y_{k_1} \leq y_1, \dots, Y_{k_n} \leq y_n] = \\ = \mathbb{P}[X_{k_1} \leq x_1, \dots, X_{k_n} \leq x_n] \cdot \mathbb{P}[Y_{k_1} \leq y_1, \dots, Y_{k_n} \leq y_n] \end{aligned}$$

- **Procesos incorrelados.** Un proceso es incorrelado consigo mismo si:

$$R_x(k, i) = \mathbb{E}[X_k] \cdot \mathbb{E}[X_i]^\top \quad \forall k \neq i$$

Dos procesos X e Y son incorrelados si:

$$R_{XY}(k, i) = \mathbb{E}[X_k] \cdot \mathbb{E}[Y_i]^\top \quad \forall k \neq i$$

Todo proceso independiente es incorrelado, pero no al revés




- Un proceso es **ergódico** cuando la información contenida en una única realización (suficientemente larga) permite estimar los estadísticos que describen a todo el proceso. Ejemplo:

$$m_X = \int \xi f_X(\xi) d\xi = \lim_{N \rightarrow \infty} \left[\frac{1}{N} \sum_{k=1}^N x_k \right] \quad R(k) = \lim_{N \rightarrow \infty} \left[\frac{1}{2N+1} \sum_{n=-N}^N x_{n+k} x_n \right]$$

- Ergodicidad implica estacionariedad, pero no a la inversa.**
- Ejemplo:** Para un proceso ergódico obtenido al filtrar un proceso gaussiano mediante el filtro

$$y_k = -0,02y_{k-1} + u_k + 0,9u_{k-1}$$

se obtiene la siguiente función de autocovarianza y densidad espectral de potencia:





- Si un proceso estocástico X tiene:
 - distribución **gaussiana**,
 - es **estacionario** en sentido estricto,
 - y sus muestras X_k son **independientes**,entonces se denomina **ruido blanco gaussiano**.
- En tal caso:

- X_k es independiente de X_i para todo $k \neq i$
- Media nula: $m_{X_k} = 0$
- Función de autocovarianza:

$$r_X(k) = \begin{cases} \sigma^2 & \text{si } k = 0 \\ 0 & \text{si } k \neq 0 \end{cases}$$

- Densidad espectral de potencia:

$$\phi_X(\omega) = \sigma^2, \quad \forall \omega$$

- La mayoría de los procesos estacionarios pueden obtenerse como salida del filtrado lineal de un proceso blanco. Es el análogo estocástico del impulso en sistemas deterministas.



- El ruido blanco E puede alimentar sistemas lineales para generar procesos con estructura.
- **Proceso MA** (Media Móvil):

$$y_k = e_k + b_1 e_{k-1} + \cdots + b_n e_{k-n}$$

- **Proceso AR** (Autorregresivo):

$$y_k + a_1 y_{k-1} + \cdots + a_n y_{k-n} = e_k$$

- **Proceso ARMA** (Autorregresivo-Media Móvil):

$$y_k + a_1 y_{k-1} + \cdots + a_n y_{k-n} = e_k + b_1 e_{k-1} + \cdots + b_n e_{k-n}$$

- **Proceso ARMAX** (ARMA con entrada exógena u_k):

$$y_k + \cdots + a_n y_{k-n} = b_0 u_{k-d} + \cdots + b_m u_{k-d-m} + e_k + \cdots + c_n e_{k-n} \cdots$$



¿Qué es el estado de un sistema?

- En sistemas deterministas (como en mecánica clásica), el **estado** es la mínima información necesaria para predecir el futuro del sistema, sin importar cómo se llegó a él.
- En sistemas estocásticos, no se puede predecir el futuro con certeza, pero sí se puede predecir su **distribución de probabilidad**.
- Surge así la noción de **modelo de espacio de estado estocástico**: el estado es la mínima información necesaria para determinar la distribución futura.

Procesos de Markov:

- Son el análogo estocástico de los modelos de estado deterministas.
- Cumplen: el futuro depende sólo del presente, no del pasado.
- Toda la evolución del sistema puede describirse mediante:
 - Una distribución inicial
 - Una ley de transición entre estados

Son fundamentales para modelar y estimar sistemas dinámicos afectados por ruido.



- Consideramos un sistema en tiempo discreto, para definir la **ecuación estocástica lineal en diferencias**.

$$x_{k+1} = \Phi x_k + e_k$$

Donde:

- Φ es una matriz determinística.
- e_k muestra de un proceso de **ruido blanco**, con:
 - $m_E = 0$
 - $r_E(k) = R_e \delta_k$
 - Independiente de x_k y de e_i , $i < k$
- Para definir completamente el proceso X , se especifican las condiciones iniciales
 - $m_{X_0} = m_0$
 - $r_{XX}(0,0) = R_x$



- **Media del proceso:**

$$m_{X_{k+1}} = \Phi m_{X_k}, \quad m_{X_0} = m_0$$

Si Φ tiene los autovalores dentro del círculo unitario, entonces la media evoluciona a 0

- **Varianza del proceso:** Sea $P_k = \sigma_{X_k}^2 = \text{Cov}(X_k, X_k) = \mathbb{E}[\tilde{X}_k \tilde{X}_k^\top]$, entonces:

$$\begin{aligned}\mathbb{E}[\tilde{x}_{k+1} \tilde{x}_{k+1}^\top] &= \mathbb{E}[(\Phi \tilde{x}_k + e_k)(\Phi \tilde{x}_k + e_k)^\top] \\ &= \mathbb{E}[(\Phi \tilde{x}_k \tilde{x}_k^\top \Phi^\top)] + \mathbb{E}[e_k e_k^\top] \\ &= \Phi \mathbb{E}[\tilde{x}_k \tilde{x}_k^\top] \Phi^\top + \mathbb{E}[e_k e_k^\top]\end{aligned}$$

$$P_{k+1} = \Phi P_k \Phi^\top + R_e, \quad P_0 = R_x$$

P_k representa la incertidumbre en el estado, $\Phi P \Phi^\top$ la propagación debida a la dinámica.

- **Función de Covarianza:**

$$\begin{aligned}\mathbb{E}[\tilde{x}_{k+1} \tilde{x}_k^\top] &= \mathbb{E}[(\Phi \tilde{x}_k + e_k) x_k^\top] \\ &= \Phi \mathbb{E}[\tilde{x}_k x_k^\top] + \cancel{\mathbb{E}[e_k x_k^\top]} \\ r_{XX}(k+1, k) &= \Phi P(k)\end{aligned}$$



- Consideramos el sistema $x_{k+1} = ax_k + e_k$ donde:
 - a es escalar.
 - e_k es ruido blanco con media 0 y desvío σ_E
- Media del estado: $m_{X_{k+1}} = a \cdot m_{X_k}$, $m_{X_0} = m_0$
- Varianza del estado: $P(k+1) = a^2 P(k) + \sigma_E^2$, $P(0) = \sigma_{X_0}^2$
- Pasado el transitorio (siempre que $|a| < 1$) la covarianza es:

$$z(P(z) - P(0)) = a^2 P(z) + \mathcal{Z}\{\sigma_E^2\}$$

$$zP(z) - a^2 P(z) = zP(0) + \mathcal{Z}\{\sigma_E^2\}$$

$$P(z) = \frac{z}{z-a^2} P(0) + \frac{z}{(z-1)(z-a^2)} \sigma_E^2$$



$$\lim_{z \rightarrow 1} \frac{z-1}{z} P(z) = \frac{\sigma_E^2}{1-a^2}$$

$$r_{XX}(i+k, i) = a^k P(i) = \frac{\sigma_E^2 a^k}{1-a^2}$$

Se convierte en estacionario pues $m = \text{cte}$ y r_X es función de la distancia entre muestras.




EJEMPLO: RESULTADOS



Ver [notebook](#) con el ejercicio resuelto.



- Un sistema lineal en tiempo discreto con función de transferencia $H(z)$ puede verse como un **filtro dinámico** aplicado a un proceso estocástico.



- La media** se propaga igual que la señal a través del filtro, y si $m_U = \text{cte}$ entonces $m_Y = H(1) m_U$

$$y_k = \sum_{n=0}^{\infty} h_n u_{k-n}$$

$$\mathbb{E}[y_k] = \sum_{n=0}^{\infty} \mathbb{E}[h_n u_{k-n}]$$

$$m_{Y_k} = \sum_{n=0}^{\infty} h_n m_{U_{k-n}}$$



- Para procesos ESA, la **covarianza** se propaga con una *doble convolución* primero con h_k y h_{-k}

$$\begin{aligned} r_Y(k) &= \mathbb{E} \left[\tilde{y}_{k+i} \tilde{y}_i^\top \right] = \mathbb{E} \left[\sum_{n=0}^{\infty} h_n \tilde{u}_{k+i-n} \sum_{m=0}^{\infty} \tilde{u}_{i-m}^\top h_m^\top \right] \\ &= \sum_{n=0}^{\infty} \sum_{m=0}^{\infty} h_n \mathbb{E} \left[\tilde{u}_{k+i-n} \tilde{u}_{i-m}^\top \right] h_m^\top = \sum_{n=0}^{\infty} \sum_{m=0}^{\infty} h_n r_U(k - n + m) h_m^\top \end{aligned}$$

- La **covarianza cruzada** entre la entrada y la salida se calcula haciendo pasar la covarianza de la entrada por el sistema, es decir, aplicando el mismo operador lineal.

$$\begin{aligned} r_{YU}(k) &= \mathbb{E} \left[\tilde{y}_{k+i} \tilde{u}_i^\top \right] = \mathbb{E} \left[\sum_{n=0}^{\infty} h_n \tilde{u}_{k+i-n} \tilde{u}_i^\top \right] \\ &= \sum_{n=0}^{\infty} h_n \mathbb{E} \left[\tilde{u}_{k+i-n} \tilde{u}_i^\top \right] = \sum_{n=0}^{\infty} h_n r_U(k - n) \end{aligned}$$



- La **densidad espectral de potencia** (PSD) de la salida está dada por:

$$\Phi_Y(\omega) = H(e^{j\omega}) \Phi_U(\omega) H^*(e^{j\omega})$$

Es la versión en frecuencia de la *doble convolución* con la autocovarianza de entrada.

- La **densidad espectral cruzada** entre entrada y salida es:

$$\Phi_{YU}(\omega) = H(e^{j\omega}) \Phi_U(\omega)$$

- Si U es ruido blanco con potencia σ^2 , entonces:

$$\Phi_U(\omega) = \sigma^2 \Rightarrow \Phi_Y(\omega) = \sigma^2 |H(e^{j\omega})|^2$$

Es decir, $|H(e^{j\omega})|^2$ actúa como *ganancia en potencia*.

- El ruido blanco es equivalente a una entrada impulso en potencia, ya que $r_U(k) = \sigma^2 \delta_k$. Esto lo hace útil para estimar la respuesta al impulso: una excitación impulso se apaga, mientras que el ruido blanco mantiene excitado al sistema.




EJEMPLO: SISTEMA DE PRIMER ORDEN

Para el sistema del ejemplo anterior

$$x_{k+1} = ax_k + e_k \Rightarrow zX(z) - aX(z) = E(z) \Rightarrow H(z) = \frac{1}{z - a}$$

$$\phi_x(e^{j\omega}) = \frac{1}{e^{j\omega} - a} \frac{1}{e^{-j\omega} - a} \sigma_E^2 = \frac{1}{1 - ae^{j\omega} + ae^{-j\omega} + a^2} \sigma_E^2 = \frac{1}{1 + a^2 - 2a \cos \omega} \sigma_E^2$$





- Dado un proceso estocástico estacionario con densidad espectral racional $\Phi_Y(\omega)$, existe un sistema lineal estable $H(z)$ tal que:

$$\Phi_Y(\omega) = H(e^{j\omega}) \cdot \Phi_U(\omega) \cdot H^*(e^{j\omega})$$

- Si la entrada es ruido blanco de media 0 y covarianza σ^2 , entonces:

$$\Phi_Y(\omega) = \sigma^2 \cdot |H(e^{j\omega})|^2$$

- **Factorización espectral:** Dada $\Phi_Y(\omega)$, se puede hallar $H(z) = \frac{B(z)}{A(z)}$, con:
 - Polos de $A(z)$ estrictamente dentro del disco unidad (estabilidad)
 - Ceros de $B(z)$ dentro o sobre el círculo unidad
- **Interpretación:** Cualquier proceso estacionario con densidad espectral racional puede generarse filtrando ruido blanco con un modelo ARMA.
- **Importancia:** basta con saber cómo se comporta un sistema ante ruido blanco para modelar cualquier perturbación estacionaria racional.



- Un proceso estocástico estacionario puede representarse como ruido blanco filtrado por $H(z)$ racional y con inversa estable $G(z)$. Entonces,

$$e_k = \sum_{n=-\infty}^k g_{k-n} y_n$$

Reemplazando en la convolución con h_k , para obtener la salida en el próximo instante,

$$y_{k+1} = \sum_{n=-\infty}^{k+1} h_{k+1-n} e_n = \sum_{n=-\infty}^k h_{k+1-n} e_n + h_0 e_{k+1} = \left[\sum_{n=-\infty}^k h_{k+1-n} \sum_{i=-\infty}^k g_{n-i} y_i \right] + h_0 e_{k+1}$$

- La salida tiene 2 términos:
 - El primero depende de sus valores anteriores, y que está formado por su mejor estimación cuadrática media.
 - El segundo contiene información nueva (o **innovación**), no contenida en el pasado: e_{k+1} es la parte nueva de y_{k+1} , no predecible con valores anteriores de y_k .
- **Importancia:** esta representación es clave para problemas de *filtrado* y *predicción*.